

# 神经架构搜索的趋势： 加速搜索

† Youngkee Kim、† Won Joon Yun、◦ Youn Kyu Lee、‡ Soyi Jung 和  
† Joongheon Kim †高丽大学电气与计算机工程系,韩国首尔 ◦弘益大学计算机工程系,韩  
国首尔韩国† 翰林大学软件学院,春川,大韩民国电子邮件:felixkim@korea.ac.kr,  
ywjoon95@korea.ac.kr, younkyul@hongik.ac.kr, jungsoyi@korea.ac.kr ,  
joongheon@korea.ac.kr

摘要 在现代深度学习研究中,寻找最优 (或接近最优)的神经网络模型是主要的研究方向之一,并在许多应用中得到广泛研究。在本文中,神经架构搜索 (NAS) 的主要研究趋势分为神经进化算法、基于强化学习的算法和一次性架构搜索方法。此外,介绍了每个研究趋势,最后比较了所有主要的三个趋势。最后,讨论了NAS研究趋势的未来研究方向。

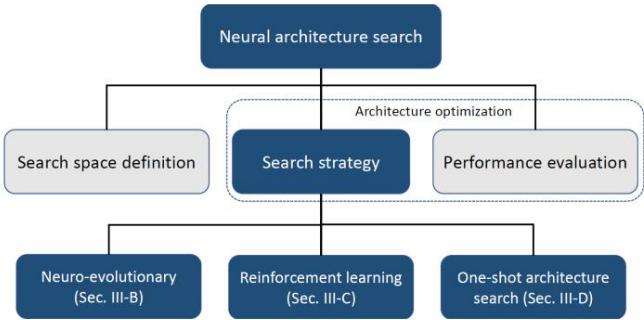


图 1:NAS 研究领域的分类。

## 一、引言

近年来,深度学习方法被广泛应用于目标检测、图像识别和自然语言处理等领域[1]。正如在许多深度学习方法中观察到的那样,它们基本上是基于启发式的非线性函数逼近,因此它们不能保证最优解 [2]。因此,根据给定任务,寻找最佳深度学习模型被视为超参数调整问题。传统上,熟练的专家根据他们的经验通过昂贵的试错过程来解决问题。这个重复的过程涉及占总成本大部分的神经网络架构的设计。因此,由于人类专家的手动工作最小化,可以降低设计新的深度学习模型的成本。从这个角度来看,现代深度学习研究中出现了神经架构搜索 (NAS)。由于神经架构设计过程的自动化,NAS 的目标是以低搜索成本获得高性能神经网络。

## 二、动机和问题陈述

在早期的 NAS 研究成果中,最重要的性能指标之一是每种搜索方法得出的最终模型的准确性。到目前为止,NAS 的有效性已被大量实验证明,其性能优于人类设计的架构。然而,由于资源和时间的限制,将NAS技术应用到各个领域并不容易。为了解决这一局限性,最近的研究侧重于降低搜索成本,同时保持可交付成果的性能。在这个趋势中,我们介绍了 NAS 的主要方法。

## 三、NAS :加速搜索

### A. 分类学

在本文中,NAS 的研究主题按图 1 所示的方式组织。从宏观的角度来看,NAS 组件可以分为搜索空间定义、搜索策略和性能评估标准。

搜索空间的定义可以被认为是可能的候选神经架构范围的规范。

这意味着考虑的神经结构越多,需要的搜索空间就越大。最终,它会导致相当大的搜索成本。已经进行了几项研究来解决这种权衡问题,但这些研究超出了本文的范围。我们重点关注神经架构优化方面的方法,包括搜索策略和性能评估标准,但下一节更侧重于搜索策略。

Zoph 等人提出了最早引入 NAS 概念的研究成果之一。阿尔。 [3]。基于强化学习的方法应用于 NAS,从 [3] 中的算法派生的神经架构已经达到了人类设计的最先进的性能。从那以后,许多相应的和相关的研究贡献被讨论并积极发展。

在本文中,我们介绍并比较了NAS的研究趋势;最后讨论未来的研究方向。我们首先看一下 NAS 研究活动的趋势。 II,然后在第 1 节中对主要方法进行分类和总结。三、在那之后,秒。 IV讨论了相应的未来研究方向,并对现有算法进行了比较。秒。 V 结束本文。

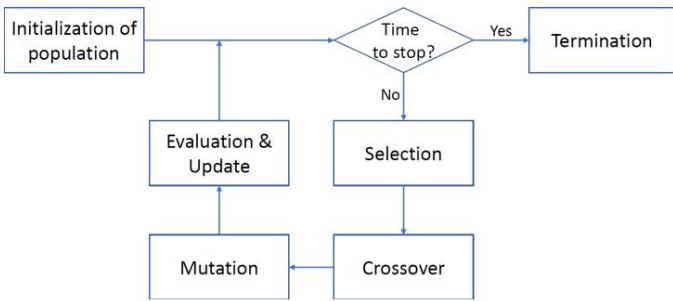


图 2:进化算法流程图。

B. 方法 1:神经进化算法

NAS 的搜索策略方法是一种神经进化算法。神经进化是一种利用进化算法生成神经网络的方法。

米勒等人第一次。阿尔。 [4] 提出了一种使用遗传算法设计神经网络架构并通过反向传播优化网络参数的方法。许多后续研究应用这种神经进化方法来发现一种新的神经网络架构。图2说明了一般进化算法计算过程的流程图。该算法进行迭代计算,直到满足搜索时间阈值和目标性能等预定义条件。

它从简单神经网络模型组成的初始种群开始。在每一个进化步骤中,从种群中抽取父模型 (选择阶段),并派生出继承每个父模型信息的新架构 (交叉阶段)。后代架构以各种方式发生变异,例如添加或删除某些层以及更改架构参数 (变异阶段)。

这个新创建的架构根据训练后的性能 (Evaluation & Update 阶段)决定是被丢弃还是注册到 population 中。

父模型采样方法、变异技术和种群更新是神经进化算法的主要研究课题。

最近,Real 等。阿尔。 [5] 引入了一种用于图像分类任务的神经网络,称为 AmoebaNet-A,它是使用改进的进化算法通过架构搜索获得的。他们将年龄属性应用于算法的锦标赛选择阶段,以倾向于支持新一代。这一改进使 AmoebaNet-A 达到了新的最先进的 ImageNet 前 5 精度。

C. 方法 2:基于强化学习 (RL) 的算法

另一种探索搜索空间的方法从根本上讲是基于强化学习 (RL) 的。该方法从 RL 的角度解决了架构搜索问题的优化。贝克等。阿尔。 [6] 进行了一项研究,以使用  $\epsilon$ -greedy Q-learning 算法生成高性能卷积神经网络 (CNN) 架构。




图 3:基于 RL 的 NAS 概览。

NAS-RL [3] 是将基于 RL 的方法应用于 NAS 的首批尝试之一。在 NAS-RL 中,神经网络架构由一种可变长度字符串表示。这种表示允许基于循环神经网络 (RNN) 的控制器通过架构参数的顺序推理对候选架构进行采样。采样神经结构的验证准确性是通过训练和验证过程获得的。这种验证准确性作为通过策略梯度方法训练控制器的奖励信号。控制器的整体学习过程如图 3 所示。

作为后续研究,Zoph 等人。阿尔。 [7] 介绍了一种生成用于图像分类的神经网络的方法,称为 NASNet,它基于 RL 搜索策略。虽然所提出的方法类似于 NAS-RL,但近端策略优化 (PPO) 应用于控制器训练。

此外,他们采用了基于单元格的搜索空间和 ScheduledDropPath,这是一种新颖的正则化技术,可实现可迁移性并提高 NASNet 中的泛化能力。尽管 NASNet 仅在 CIFAR-10 上进行训练,但它在 ImageNet 上稍作调整即可达到合理的精度。

D. 方法 3:一次性架构搜索

使用一次性架构搜索方法,我们可以尝试替代方法而不是传统方案。在早期的 NAS 工作中,每个候选架构的训练过程通常是高成本的。基于这一观察,一次性架构搜索的关键目标是最小化搜索过程中的训练成本。一次性架构搜索的概念非常全面,我们在本文中描述了一些有代表性的方法。

参数共享。参数共享是深度学习中使用最广泛的方法之一。从 NAS 的角度来看,很明显,从头开始训练每个候选架构会导致巨大的计算成本。换句话说,将考生在每次培训中获得的知识都扔掉是一种极大的浪费。首先,ENAS [8] 是将参数共享引入 NAS 的初步研究之一。

ENAS 的整个搜索空间被看作是一个过参数化的网络,用有向无环图来表示。基于 LSTM 的控制器搜索这个大图子图以获得最佳神经网络架构。这种方法允许所有候选人共享他们的参数,而无需从

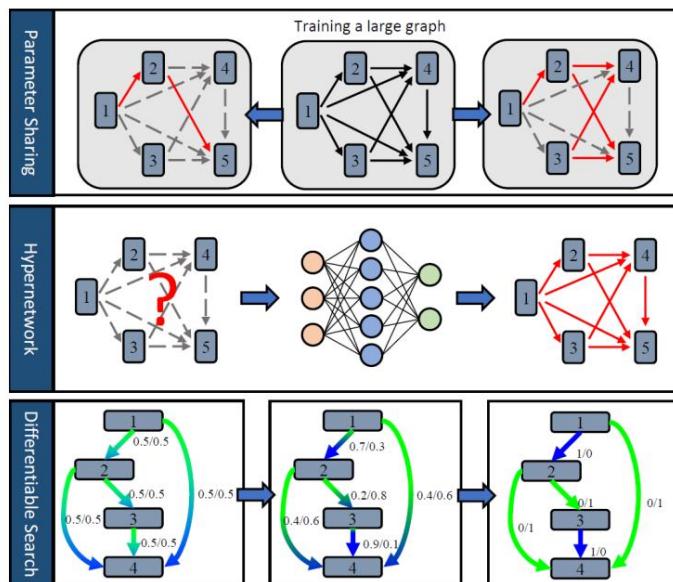


图 4:一次性架构搜索方法。

划痕。图 4 中的第一行描述了具有参数共享的子图采样。

超级网络。超网络在 [11] 中作为神经网络被提出,用于为其他更大的网络 (例如 CNN 和 LSTM)生成非共享权重。布鲁克等。阿尔。 [12] 应用这种技术来预测候选架构的性能。图 4 中的中间一行可视化了学习为给定架构生成权重的超网络的作用。这个超网络可以对候选架构进行排名并确定其中的最佳架构。最近,张等人。阿尔。 [9] 用图神经网络的概念改进了这种方法。他们提出了 Graph HyperNet work (GHN),它通过对给定架构的拓扑建模来更准确地预测性能。

可微搜索。大多数 NAS 方法的基本前提是架构搜索的优化问题是离散域上的黑盒优化。

随着搜索空间的生长,这一事实自然会导致大量的计算和搜索时间。为了解决这个问题,DARTS [10] 出现了对搜索空间定义的不同观点。顾名思义,DARTS 通过对架构表示应用连续松弛来获得可微分的搜索空间。获得优化的单元单元结构的过程如图4底部所示。单元由有向无环图表示,每个节点表示潜在表示,每条边表示具有连续概率的候选操作的混合。这些参数化概率和整个体系结构的权重通过梯度下降法求解双层优化问题同时进行优化。

#### 四、讨论和未来的研究方向

在本节中,我们将通过总结每种方法的优缺点来讨论哪种方法在搜索时间方面是未来研究的更好起点。

我们介绍的第一种方法是神经进化算法。这种方法的好处在本质上类似于进化。它允许搜索具有高鲁棒性的神经架构,而不管问题的性质如何。此外,这种基于种群的方法能够并行探索搜索空间的多个部分,提供避免局部最优的机会。另一方面,神经进化算法在计算成本和学习速度方面存在弱点。评估步骤的数量随着人口和训练样本的规模而急剧增加。此外,代代相传的学习需要相当多的时间。

接下来是基于强化学习的方法,训练代理生成性能良好的神经架构。基于 RL 的算法的学习原理与人类的相似。因此,相对清楚的是,最终模型优于人类专家设计的模型。然而,由于重复的动作和奖励过程,大量的搜索时间是不可避免的。

如前一节所述,一次性架构搜索的目标是最小化候选神经架构的训练成本。很容易预测这种动机导致节省总搜索时间。如表 1 所示,一次性架构搜索算法在搜索时间方面取得了显着改进。此表中的性能指标基于 CIFAR-10。然而,这种方法意味着一次大型计算图的训练或整个搜索空间的优化。因此,一次性架构搜索方法比其他方法需要更大的内存空间。

虽然加速搜索过程仍然是主要的改进点之一,但现在是时候考虑如何将这些加速的 NAS 技术以实用的方式应用到各个领域了。NAS-Unet [13] 是将 NAS 扩展到医学领域的研究之一。顾名思义,NAS-Unet 的灵感来自 U-Net [14],它广泛用于生物医学中的图像分割。NAS-Unet 是通过所提出的 NAS 方法发现的,该方法应用基于 U 型骨干架构的可微分架构搜索策略。与没有任何预训练的 U-Net 相比,它获得了更好的性能和更少的参数。

#### 五、结束语

在本文中,NAS 研究的主流被分类为神经进化算法、基于强化学习的算法和一次性架构搜索方法。

此外,每个研究方向都被概括为一个核心思想,以及具有代表性的研究案例。有了这个总结,对 NAS 感兴趣的研究人员可以获得基础知识,从而设置一个良好的起点。

方法	优势	坏处	参考	准确性	参数 GPU 天数
神经进化算法	鲁棒性	搜索时间慢	变形虫网-A [5]	96.66 ± 0.06%	3.2M 3150
强化学习	性能保证	搜索时间慢	NASNet-A + 抠图 [7]	97.35%	3.3M 2000
一次性架构搜索	快速搜索时间	超大内存空间	ENAS + 镂空 [8]	97.11%	4.6M 0.45
			生长激素 [9]	97.16 ± 0.07%	5.7M 0.84
			DARTS (一阶)+ cutout [10]	97.00 ± 0.14%	3.3M 1.5

表 I:NAS 中主要方法的总结。

致谢

这项工作得到了韩国政府 (MSIT) 资助的信息与通信技术规划与评估研究所 (IITP) 赠款的支持 (编号 2021-0-00766,支持自动神经网络生成和部署优化的集成开发框架的开发运行时环境)。 Joongheon Kim 是该论文的通讯作者。

参考

[1] J. Park,S. Samarakoon,A. Elgabli,J. Kim,M. Bennis,S.-L. Kim 和 M. Debbah,“无线网络上的高效通信和分布式学习:原理和应用”,IEEE 会刊,卷。 109,没有。 5,第 796-819 页,2021 年 5 月。

[2] M. Shin,J. Kim 和 M. Levorato,“基于拍卖的多无人机网络深度学习框架充电调度”,IEEE Trans actions on Vehicular Technology,vol. 68,没有。 5,第 4235–4248 页,2019 年 5 月。

[3] B. Zoph 和 QV Le,“带强化的神经结构搜索学习”,arXiv 预印本 arXiv:1611.01578,2016 年。

[4] GF Miller,PM Todd 和 SU Hegde,“使用遗传算法设计神经网络”,Proc.国际遗传算法会议 (ICGA),第一卷。 89, 1989, 第 379–384 页。

[5] E. Real,A. Aggarwal,Y. Huang 和 QV Le,“图像分类器架构搜索的正则化演化”,Proc. AAAI 人工智能会议,卷。 33,没有。 2019 年 1 月,第 4780–4789 页。

[6] B. Baker,O. Gupta,N. Naik 和 R. Raskar,“使用强化学习设计神经网络架构”,arXiv 预印本 arXiv:1611.02167,2016 年。

[7] B. Zoph,V. Vasudevan,J. Shlens 和 QV Le,“学习用于可扩展图像识别的可迁移架构”,Proc. IEEE 计算机视觉和模式识别会议 (CVPR),2018 年,第 8697–8710 页。

[8] H. Pham,M. Guan,B. Zoph,Q. Le 和 J. Dean,“通过参数共享进行高效的神经架构搜索”,Proc.机器学习国际会议 (ICML)。 PMLR,2018 年,第 4095–4104 页。

[9] C. Zhang,M. Ren 和 R. Urtasun,“用于神经架构搜索的图超网络”,arXiv 预印本 arXiv:1810.05749,2018 年。

[10] H. Liu,K. Simonyan 和 Y. Yang,“飞镖:可微架构搜索”,arXiv 预印本 arXiv:1806.09055, 2018 年。

[11] D. Ha,A. Dai 和 QV Le,“超网络”,arXiv 预印本 arXiv:1609.09106,2016 年。

[12] A. Brock,T. Lim,JM Ritchie 和 N. Weston,“Smash:通过超网络进行一次模型架构搜索”,arXiv 预印本 arXiv:1708.05344,2017 年。

[13] Y. Weng,T. Zhou,Y. Li 和 X. Qiu,“NAS-Unet:医学图像分割的神经结构搜索”,IEEE Access,卷。 7,第 44 247–44 257 页,2019 年。

[14] O. Ronneberger,P. Fischer 和 T. Brox,“U-Net:用于生物医学图像分割的卷积网络”,Proc.医学图像计算和计算机辅助干预国际会议.斯普林格,2015 年,第 234-241 页。