

基于进化算法的残差块搜索压缩伪影移除

里希尔沙阿

电气工程系 SV 国家理工学院 印度苏拉特

rishil2008@gmail.com

摘要 有损图像压缩普遍用于较低速率的存储和传输。在现有的有损图像压缩方法中, JPEG 标准是多媒体世界中使用最广泛的技术。多年来, **已经提出了许多方法来抑制 JPEG 压缩图像中引入的压缩伪影。**

然而, 目前所有基于学习的方法都包括由研究人员手动设计的深度卷积神经网络 (CNN)。网络设计过程需要大量的计算资源和专业知识。着眼于这个问题, 我们研究了进化搜索, **以寻找基于残留块的最佳架构来去除伪影。**我们首先定义了一个残差网络结构及其在搜索中使用的相应基因型表示。然后, 我们提供了用于寻找最佳残差块架构的进化算法和多目标函数的详细信息。最后, 我们展示了实验结果来表明我们的方法的有效性, 并将性能与现有的工件去除网络进行比较。所提出的方法可扩展且可移植到许多低级视觉任务。

以及提高基于传统混合编码框架的编码性能的难度增加, 用于图像压缩的端到端优化 CNN 框架正在得到广泛开发 [2]、[14]、[15]。尽管开发了具有明显更好性能的新型压缩方法, 但 JPEG 仍然是最流行的有损图像压缩标准 [16]。由于 JPEG 压缩图像仍在从摄影到网页的众多应用中广泛使用, JPEG 在当前多媒体世界中的重要性是显而易见的。

JPEG 压缩标准涉及基于块的离散余弦变换 (DCT)。给定的图像被分成 8×8 块, 然后使用 2-D DCT 将其转换为频域。这之后是量化步骤, 其中丢弃高频信息同时保留低频信息。**由于去除了高频分量, DCT 系数的量化引入了振铃和模糊伪影。**除此之外, JPEG 压缩中使用的块变换编码方法会导致在低频区域中最明显的块效应 [8]。

索引词: 进化算法, 伪影去除, 残差网络, 图像处理

一、引言

近年来信息爆炸, 多媒体压缩已成为机构和公司的关键和不可避免的, 以利用有限的存储和传输能力。随着图像采集设备越来越普遍, 图像数据的增长速度远远超过压缩技术的进步。

图像压缩的目标是尽量减少图像中的冗余, 以便以低比特率进行存储和传输。压缩技术有两种类型: 1) 有损 (例如 JPEG、JPEG2000) 和 2) 无损 (例如 BMP、PNG) [1]。

无损压缩保留图像质量并提供原始图像的完美重建, 而有损压缩提供更高的压缩比。因此, 无损压缩被用于医学图像、科学绘图和其他与原始图像有任何差异是不可接受的应用。然而, 大多数图像数据的目的是通过显着降低比特率来减少质量损失 [1]。

深度卷积网络显著提高了低级图像处理任务的性能, 如单幅图像超分辨率 [4]、[11]–[13] 和图像去噪 [6]、[7]、[17]。董等。 [3] 应用了受 SRCNN [4] 启发的端到端卷积网络框架来抑制压缩伪影。ARCNN [3] 实现的质量显着提高已将重点从边缘感知去噪 [18]、[19] 和稀疏恢复算法 [20]、[21] 转移到基于深度学习的方法。图形处理单元 (GPU) 的商业可用性和价格的急剧下降, 加上残差和密集连接网络 [22]、[23] 的发展, 导致深度 CNN 被用于众多图像处理应用。使用 12 层 ConvNet [5] 和具有跳跃连接 [8] 的 L8 架构的 CAS-CNN 被广泛认为是用于去除压缩伪影的架构。这种基于深度 CNN 的方法用于图像去噪和伪影去除等低级图像处理任务, 强调增加网络参数以提高性能。然而, 这种手动设计的网络中的卷积层通常共享相同的架构规范, 这可能并不总是最优的

由于深度卷积神经网络 (CNN) 在高级计算机视觉任务中的巨大成功

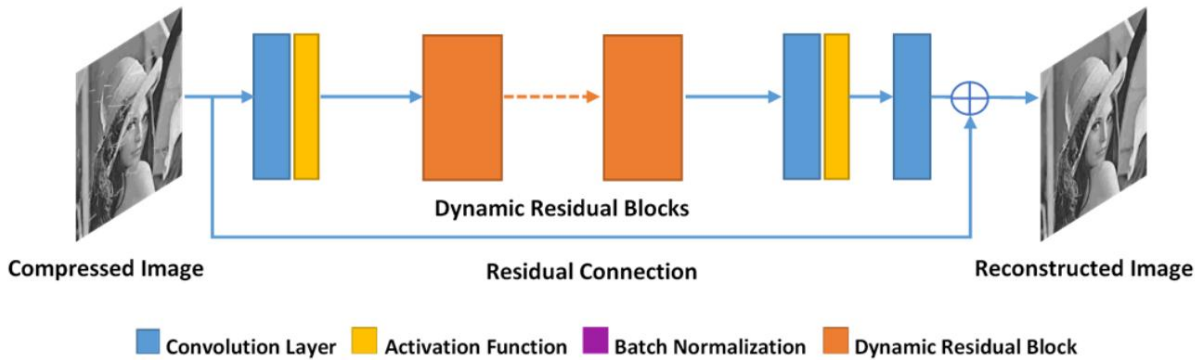


图 1. 启用残差学习的动态残差网络 (DRN) 架构。




图 2. 搜索空间中包含的动态残差块 (DRB) 架构示例。

对于任务,影响整个网络的性能和容量。

近年来,神经架构搜索 (NAS) 已成功地在图像分割 [24]、去噪 [25] 和恢复 [26] 任务上实现了最先进的性能。

尽管最近在图像超分辨率的邻近领域探索了 NAS,但尚未对其去除压缩伪影进行研究。给定弹性搜索空间,NAS 能够生成高质量模型,其性能可与图像超分辨率中的最新技术相媲美 [28]。然而,在组合的微观和宏观空间上进行弹性搜索需要大量计算并且耗时。相反,Zhong 等人概述了一种更实用的方法。它侧重于用于自动网络生成的基于块的设置 [27]、[29]。ESRN 网络的性能证实了图像超分辨率方法的有效性 [11]。

鉴于 JPEG 图像在当今多媒体世界中的重要性,压缩伪影去除是一个广泛研究的低级图像处理问题。随着深度学习的出现和高端计算资源的商业化,许多基于 CNN 的架构被提出。然而,所有现有的基于学习的方法都具有由研究人员手动设计的深层 CNN 架构。在本文中,我们提出了一种基于进化的方法来寻找最佳的基于块的架构,以去除 JPEG 压缩图像中的伪影。我们首先概述开发深度 CNN 网络的策略

通过使用进化搜索找到的动态残差块 (DRB) 的顺序连接来跳过连接。牢记在为低级视觉任务 [3]、[8]、[12] 训练更深层网络时遇到的收敛和缩放问题,我们在搜索空间中包括训练超参数,例如残差学习和权重初始化。我们描述了一种基于整数的网络编码策略,它允许直接应用已建立的进化策略和操作。我们在实验中使用了通常报告的基准数据集和性能指标 [3]、[5]、[6]、[8]、[21]、[30]。

二.相关工作

A.压缩伪影去除基于深度学习的方法已经

成为几乎所有高级计算机视觉问题的最先进方法。

继董等人的突破之后。[4] 在使用 SRCNN 实现卓越的图像超分辨率时,在图像超分辨率和伪影去除的并行域中也出现了类似的趋势。紧凑高效的伪影去除网络 - ARCNN [3] 通过嵌入多个特征增强层改进了 SR CNN 架构,与传统的伪影去除方法相比,图像质量有了显着提高。

为了解决 Dong 等人面临的收敛问题。在训练更深的 CNN 网络 [3] 时, Svoboda 等人。在他们的伪影去除网络中采用了跳跃连接、残差学习和对称权重初始化 [8]。

同年,Cavigelli 等人。提出了具有分层跳跃连接的 CAS-CNN 架构,并用多尺度损失函数替换了传统的均方误差 (MSE) 损失 [5]。网络和训练过程中的修改允许 12 层 ConvNet 收敛到超过最先进的精度。

与开发更深的 CNN 网络相比,Guo 等人。提出了 DDCN,一种基于双域 CNN 的模型,将 DCT 域先验与 CNN 架构集成 [21]。

双域方法进一步纳入 DMCNN 模型,该模型基于自动编码器样式架构并使用多尺度损失 [17]。此外,Galteri 等人。使用生成对抗网络去除伪影 [30],而 SFCNN 架构 [10] 在降低计算成本的情况下提高了性能。

B. 深度残差网络

与许多计算机视觉问题中较浅的 CNN 对应物相比,残差网络取得了更好的结果。在过去的几年里,它们在图像超分辨率 [11]-[13],[31]-[33] 和压缩伪影去除 [7]-[9] 架构方面得到了广泛研究。林等。确定了直接实施 ResNet 架构 [22] 以解决低级视觉问题的缺点,并提出了一种改进的残差块以获得最佳的超分辨率性能 [31]。他们增强的深度残差网络 EDSR 通过移除计算量大的批量归一化层并采用残差缩放对现有的 SRResNet [33] 进行了改进。

然而,所有之前的深度残差网络都未能结合层次特征进行重建。张等。通过引入由较小的剩余密集块 (RDB) 组成的剩余密集网络 (RDN) 来解决此缺陷

[13]。RDN 网络有一个连续的内存机制,通过前面的 RDB 和当前 RDB 的所有层之间的直接链接合并。为了全局保留层次特征,网络在提取局部密集特征后使用密集特征融合 (DFF)。最近,Song 等人。提出了通过搜索有效的 RDB [11] 实现图像超分辨率的 ESRN 架构。

三、提议的方法

定义合适的搜索空间对于降低计算成本和提高 NAS 算法的性能至关重要。现有文献 [6],[7],[9],[11],[13],[29],[31] 已经证实了**基于块的架构对低级视觉任务的有效性**。我们首先在下一节中使用整数呈现动态残差网络及其相应的基因型表示。

接下来,我们概述了进化搜索算法和使用的运算符。

A. 动态残差网络

用于伪影去除的端到端 CNN 框架

包括四个操作:特征提取,映射,增强和重建[3]。如图 1 所示,动态残差网络 (DRN) 由预定义的

表 1用于DRB		
架构和网络训练的参数搜索空间。		
块参数	参数值	等位基因
块状态	{不活跃,活跃} {1, 2,	{0, 1}
卷积层	3, 4} {8, 16, 32,	{0, 1, 2, 3}
过滤器数量	64} {1, 3, 5, 7, 9,	{0, 1, 2, 3}
过滤器尺寸	11}	{0, 1, 2, 3, 4, 5}
批量归一化	缺席,出席	{0, 1} {0, 1,
激活函数	{Leaky ReLU, ReLU, SELU}	2} {0, 1}
跳过连接	缺席,出席	
训练参数	参数值	等位基因
剩余学习	缺席,出席	{0, 1}
权重初始化	{无,高斯,对称}	{0, 1, 2}




图 3. DRN 基因型示例。

基于L8架构的特征提取和重建层[8]。我们的工作重点是使用中间动态残差块 (DRB) 的进化搜索来寻找更重要的特征增强和非线性映射层。除了卷积层之外,图 2 (b)中给出的 DRB 架构还使用了跳跃连接和批量归一化层。每个 DRN 映射到一个长度为 44 的染色体,其中前 42 个基因模拟 6 个 DRB,每个 7 个基因,最后 2 个基因分别代表残差学习和权重初始化。染色体长度限制为 44 以减少进化搜索的计算成本,并且可以根据资源的可用性增加。每个 DRB 都被编码为{块状态,块参数},其中块状态的值决定该块是否包含在网络中。每个参数都通过使用基于 0 的整数编码策略 (表 1)映射到基因型中,该策略允许直接使用已建立的进化算子。图 3 显示了带有第一个 DRB 和训练参数映射的样本染色体,如表 1 所示。第一个基因的值为 1 表示第一个 DRB 包含在最终网络中。

B. 基于进化算法的残差块搜索

1)进化算法:用于架构搜索的进化算法概述如下。首先,随机选择大小为 P 的初始种群,并对每个个体的适应度进行评估。现在,我们根据预定义的精英数量 T 将精英个体Em即最适者放在一边。精英方法在我们进化种群时保留最适者,确保候选解决方案的质量不会随着我们的进化而降低从一代到另一代。在每个世代周期开始时,我们使用锦标赛选择从 P 中选择父母。

后代是根据给定的交叉概率pcross 使用所选双亲的模拟二元交叉生成的。接下来,后代的突变是

由产生变异个体的有界多项式变异算子执行。高突变概率 p_{mut} 促进了对新候选解决方案的探索,但同时防止了对当前一代中合适个体的利用。变异后,我们评估新生成的个体的适应度并相应地更新 P 和 E_m 。进化搜索过程如下:

输入:种群规模 P 、最大世代数 M 、交叉概率 p_{cross} 、变异概率 p_{mut} 、精英数 T 、训练数据集 D_{train} 、验证数据集 D_{val} 。

初始化: (i) 所有个体的适应度 F_P (ii) 精英主义
 $E_m \leftarrow U_pdate(F_P, T)$
while $m \leq M$ do
 $parents \leftarrow Selection(P, F_P, T)$
 $offsprings \leftarrow Crossover(parents, m_{cross})$
 $mutated \leftarrow Mutation(offsprings, m_{mut})$ 模型
 $\leftarrow T_rain(mutated, D_{train})$
 $F_P \leftarrow 评估(模型, D_{val})$
 $E_m \leftarrow 更新(F_P, T, E_m - 1)$
 $P \leftarrow 突变 + E_m$
 $m + 1$ 结束 while

输出:精英主义 E_m

2) 适应度评估:为了确定每个单独解决方案的适应度,我们首先将基因型映射到其相应的 DRN 结构和训练参数。然后我们在 D_{train} 数据集上针对给定的 epoch 数训练网络,并评估其在验证数据集 D_{val} 上的性能。对于压缩伪影去除,峰值信噪比 (PSNR) 和结构相似性指数 (SSIM) 是使用最广泛的性能指标 [3],[5],[6],[8],[21],[30]。因此,在进化过程中,我们使用这两个指标来评估候选解决方案的性能。

为了探索有效的网络,我们还在其中一个进化搜索试验中使用参数的数量作为目标。因此,我们考虑工件去除任务的三个目标,

- 评估网络噪声去除能力的定量指标 (PSNR), ·评估结构内容检索的定量指标
 - 网络能力 (SSIM), ·网络参数数量。
- 总的来说,这转化为我们使用 NSGA-II 方法 [28] 的多目标问题。

四、实验

一、实施

我们在实验中使用 BSD500 [34]、LIVE1 [35] 和 Classic5 数据集。BSD500 数据集由 200 个训练图像和 200 个验证图像组成,它们被合并以获得训练数据集,而 29 个 LIVE1 和 5 个 Classic5 图像用作测试数据集。RGB 图像使用 YCbCr 颜色模型进行转换,仅使用亮度

表 II 进化搜索			
参数和适应性评估目标。			
搜索参数	第一次搜索	第二次搜索 3	搜索
最大世代	40	60	60
人口规模	30	25	30
突变概率	0.2	0.2	0.3
精英数	50	50	50
历元数	20	20	10
比赛规模	20	20	50
评价目标	第一次搜索	第二次搜索 3	搜索
峰值信噪比	是的	是的	是的
SSIM卡	是的	是的	是的
网络参数	不	不	是的

表三			
进化搜索最佳性能模型。			
性能指标	DRN-Es1	DRN-Es2	DRN-Es3
峰值信噪比	28.26	28.09	27.95
SSIM卡	0.794	0.791	0.785
网络参数	533k	495k	313k

- 保留 Y 分量。根据之前的论文,训练图像和测试图像都使用品质因数 (QF) 为 10 的 MATLAB JPEG 编码器进行压缩。

实验是在配备 12GB Tesla K80 GPU 的服务器上使用用于深度学习的 PyTorch 框架 [37] 和用于进化搜索的 DEAP 框架 [36] 进行的。

B. 搜索细节

对于在进化搜索过程中对单个网络的训练,我们使用来自 BSD500 训练集图像的 32×32 随机裁剪的补丁。使用缩放和旋转来增加 400 张图像以增加数据大小。

使用 64 的小批量大小,并使用 L1 范数作为原始图像和重建图像之间的损失标准。我们在进化搜索期间使用大小为 32×32 的训练图像,以在合理的计算时间内容纳更大的训练集。在训练给定数量的 epoch 后,每个候选解决方案都会 在 29 个 LIVE1 数据集图像上进行评估。如表 2 所述,第 2 次进化搜索实验仅根据重建质量评估模型 1,而第3 次实验还考虑了网络参数。

表 II

我们在实验中增加了最大世代,以强调探索而不是利用。每次搜索产生的最佳网络的性能和参数数量如表3所示。第 n 次进化搜索产生的最佳网络称为 DRN-Es n 。

C. 再培训细节

进化后,性能最佳的架构使用来自训练数据集的 64×64 随机裁剪的补丁进行再训练。使用 64 的小批量大小,类似于搜索阶段,使用 L1 范数作为损失准则。

我们用10-3的学习率初始化 Adam 优化器




图 4. LIVE1 数据集中图像 “monarch” (QF = 10)的伪影去除结果。

表 IV LIVE1
和CLASSIC5 数据集的重建图像质量比较。

数据集质量		公制JPEG		SA-DCT ARCNN 快速 ARCNN		L4	DnCNN-3 DRN-Es1 DRN-Es2 DRN-Es3			
				[18]	[3]	[3]	[6]	(我们)	(我们)	(我们)
居住	10	峰值信噪比 (分贝)	27.77	28.65	29.13	29.10	29.08	29.19	29.25	29.22
		SSIM卡	0.791	0.809	0.823	0.824	0.824	0.826	0.831	0.826
经典5	10	峰值信噪比 (分贝)	27.82	28.88	29.04	29.03	-	29.40	29.34	29.32
		SSIM卡	0.780	0.807	0.811	0.812	-	0.820	0.822	0.819

每 20k 次迭代按比例缩小 2。我们设置参数 $\beta_1 = 0.9$ 和 $\beta_2 = 0.999$ 。迭代次数固定为 100k,比用于训练 ARCNN [3] 的 107 少 100 倍,大约是 [8] 中报告的 250k 迭代次数的 0.5 倍。

用于再训练的信息。较小的数据集和训练迭代减少了计算成本,但同时限制了图像质量的提高。特别是对于 DRN Es1,更大的数据集和更大的图像尺寸应该可以显著提高重建图像的质量。图 5 显示了所有三个网络的重建图像。

D. 结果与讨论

表 4 给出了搜索架构与参考伪影去除模型的性能比较。DRN-Es1 实现的 29.25 dB 的 PSNR 和 0.831 的 SSIM 是对普通 JPEG 压缩图像的显着改进。正如所指出的,所有 3 个生成网络的性能与其他基于 CNN 的伪影去除网络相当。基于进化搜索结果,我们能够推断残差学习在性能上提供了实质性的改进,并适应了更高的训练率。我们尝试使用可调梯度裁剪 [8] 将学习率提高到 0.1,结果证明是徒劳的,我们选择不包括低于标准的模型性能。

基于搜索结果的另一个重要观察结果是,大多数精英网络中都没有批量归一化层。这在第 3 次进化搜索的情况下尤为明显,这表明批量归一化层几乎没有提供质量改进,但显着增加了网络参数。

进化搜索期间训练时期的有限数量限制了搜索,减少了计算时间并生成了快速收敛的网络。DRN Es1 模型能够在仅 40k 次迭代内超越 ARCNN 的性能。尽管网络规模较小,但 DRN-Es3 在图像质量方面表现出相当不错的改进,超过了除 DnCNN-3 [6] 之外的所有其他方法。

然而,我们认为生成的网络的性能受到相对较少的 iter 数量的限制

五. 结论和未来工作

在本文中,我们提出了一种基于进化算法的压缩伪影去除搜索。大多数现有的工件去除网络都是由研究人员手动设计的,需要领域专业知识。另一方面,所提出的进化搜索能够生成深度神经网络,克服手动设计网络的性能限制,而不必依赖领域知识。我们提出了一种基于残差块组件的残差网络架构,它是从给定的参数空间中搜索出来的。生成的网络能够获得比现有的基于 CNN 的伪影去除网络更好的结果,而且训练迭代次数要少得多。随着集成空间和 DCT 域信息的双域网络变得越来越流行,我们相信下一步的研究将采用进化搜索来寻找最佳双域网络。我们相信我们的工作为采用进化算法和开发更适合低级视觉任务的深度残差网络提供了见解。

参考

[1] Z. Wang,AC Bovik 和 L. Lu,“为什么图像质量评估如此困难?” ,IEEE 声学语音和信号处理国际会议 ,2002 年 5 月。
[2] S. Ma,X. Zhang,C. Jia,Z. Zhao,S. Wang 和 S. Wang,“使用神经网络进行图像和视频压缩 :综述” , IEEE 视频技术电路和系统汇刊,卷。 30,没有。 6,第 1683–1698 页,2020 年 6 月。



图 5. LIVE1 数据集中图像“monarch”(QF = 10)的伪影去除结果。

[3] C. Dong,Y. Deng,CC Loy and X. Tang, “通过深度卷积网络减少压缩伪影” ,2015 年 IEEE 计算机视觉国际会议 (ICCV),2015 年 12 月。

[4] C. Dong,CC Loy,K. He 和 X. Tang, “使用深度卷积网络的图像超分辨率” ,IEEE 模式分析和机器学习交易,卷。 38,没有。 2,第 295-307 页,2016 年 2 月。

[5] L. Cavigelli,P. Hager 和 L. Benini, “CAS-CNN:用于图像压缩伪影抑制的深度卷积神经网络” ,2017 年国际神经网络联合会 (IJCNN),2017 年 5 月。

[6] K. Zhang,W. Zuo,Y. Chen,D. Meng 和 L. Zhang, “超越高斯降噪器:用于图像降噪的深度 CNN 的残差学习” , IEEE 图像处理交易,卷。 26,没有。 7,第 3142-3155 页,2017 年 7 月。

[7] Y. Tai,J. Yang,X. Liu 和 C. Xu, “MemNet:用于图像恢复的持久内存网络” ,2017 年 IEEE 计算机视觉国际会议 (ICCV),2017 年 10 月。

[8] P. Svoboda,M. Hradis,D. Barina 和 P. Zemcik: “使用卷积神经网络去除压缩伪影” ,J. WSCG,卷。 24,没有。 2,第 63-72 页,2016 年。

[9] B. Zheng,R. Sun,X. Tian 和 Y. Chen: “S-Net:用于 JPEG 压缩伪影减少的可扩展卷积神经网络” ,电子成像杂志,卷。 27,没有。第 4 页043037, 2018.

[10] T. Kim,H. Lee,H. Son 和 S. Lee, “SF-CNN:通过空间到频率卷积神经网络快速去除压缩伪影” ,2019 年 IEEE 图像处理国际会议 (ICIP),2019 年 9 月。

[11] D. Song,C. Xu,X. Jia,Y. Chen,C. Xu 和 Y. Wang, “Efficient Residual Dense Block Search for Image Super-Resolution” ,AAAI 人工智能会议论文集,卷。 34,没有。 07,页。 12007-12014,2020 年 4 月。

[12] J. Kim,JK Lee 和 KM Lee, “使用超深卷积网络的精确图像超分辨率” ,2016 年 IEEE 计算机视觉和模式识别 (CVPR) 会议,2016 年 6 月。

[13] Y. Zhang,Y. Tian,Y. Kong,B. Zhong 和 Y. Fu, “用于图像超分辨率的残差密集网络” ,2018 年 IEEE/ CVF 计算机视觉和模式识别会议,2018 年 6 月。

[14] J. Balle,V. Laparra 和 EP Simoncelli, “端到端优化图像压缩” ,arXiv 预印本 arXiv:1611.01704, 2016 年。

[15] L. Theis,W. Shi,A. Cunningham 和 F. Huszar, “使用压缩自动编码器进行有损图像压缩” ,arXiv 预印本 arXiv:1703.00395,2017 年。

[16] G. Hudson,A. Leger,B. Niss,J. Sebestyen 和 J. Vaaben, “JPEG-1 标准 25 年:成功的过去,现在和未来原因” , 电子成像杂志,第一卷。 27,没有。 04,页。 1,2018 年 8 月。

[17] X. Zhang,W. Yang,Y. Hu 和 J. Liu, “Dmccnn:用于压缩伪影去除的双域多尺度卷积神经网络” ,2018 年第 25 届 IEEE 图像处理国际会议 (ICIP), 2018 年 10 月。

[18] A. Foi,V. Katkovnik 和 K. Egiazarian, “Pointwise Shape-Adaptive DCT for High-Quality Denoising and Deblocking of Grayscale and Color Images” ,IEEE 图像处理汇刊,卷。 16,没有。 5,第 1395-1411 页,2007 年 5 月。

[19] K. Dabov,A. Foi,V. Katkovnik 和 K. Egiazarian, “通过稀疏 3-D 变换域协同过滤进行图像去噪” , IEEE Transactions on Image Processing,vol. 16,没有。 8,第 2080-2095 页,2007 年 8 月。

[20] X. Liu,X. Wu,J. Zhou 和 D. Zhao, “双变换像素域中基于数据驱动的基于稀疏性的 JPEG 压缩图像恢复” ,2015 年 IEEE 计算机视觉和模式识别会议 (CVPR),2015 年 6 月。

[21] J. Guo 和 H. Chao, “构建双域表示以减少压缩伪影” ,计算机科学讲义,第 628-644 页,2016 年。

[22] K. He,X. Zhang,S. Ren 和 J. Sun, “图像识别的深度残差学习” ,2016 年 IEEE 计算机视觉和模式识别会议 (CVPR),2016 年 6 月。

[23] G. Huang,Z. Liu,L. Van Der Maaten 和 KQ Weinberger, “密集连接的卷积网络” ,2017 年 IEEE 计算机视觉和模式识别 (CVPR) 会议,2017 年 7 月。

[24] C. Liu, L.-C. Chen, F. Schroff, H. Adam, W. Hua, AL Yuille 和 L. Fei-Fei, “Auto-DeepLab:用于语义图像分割的分层神经架构搜索” ,2019 年 IEEE/CVF 计算机视觉和模式识别会议(CVPR),2019 年 6 月。

[25] H. Zhang,Y. Li,H. Chen 和 C. Shen, “用于图像去噪的高效内存分层神经架构搜索” ,2020 年 IEEE/ CVF 计算机视觉和模式识别 (CVPR) 会议,6 月。 2020.

[26] H. Zhang,Y. Li,H. Chen,C. Shen: “Ir-nas:图像恢复的神经结构搜索” ,arXiv 预印本 arXiv: 1909.08228。

[27] Thomas Elsken,Jan Hendrik Metzen 和 Frank Hutter: “神经架构搜索:一项调查。” arXiv 预印本 arXiv:1808.05377,2018b。

[28] Chu X.,Zhang B.,Ma H.,Xu R.,Li J. 和 Li Q.: “快速、准确和轻量级的超分辨率与神经结构搜索。” arXiv 预印本 arXiv:1901.07261。

[29] Z. Zhong,J. Yan,W. Wu,J. Shao 和 C.-L. Liu, “实用块级神经网络架构生成” ,2018 年 IEEE/CVF 计算机视觉和模式识别会议,2018 年 6 月。

[30] L. Galteri,L. Seidenari,M. Bertini 和 AD Bimbo, “Deep Generative Adversarial Compression Artifact Removal” ,2017 年 IEEE 计算机视觉国际会议 (ICCV),2017 年 10 月。

[31] B. Lim,S. Son,H. Kim,S. Nah 和 KM Lee, “用于单幅图像超分辨率的增强型深度残差网络” ,2017 年 IEEE 计算机视觉和模式识别研讨会 (CVPRW), 2017 年 7 月。

[32] J. Kim,JK Lee 和 KM Lee, “用于图像超分辨率的深度递归卷积网络” ,2016 年 IEEE 计算机视觉和模式识别会议 (CVPR),2016 年 6 月。

[33] C. Ledig,L. Theis,F. Huszar,J. Caballero,A. Cunningham,A. Acosta,A. Aitken,A. Tejani,J. Totz, Z. Wang 和 W. Shi, “照片-使用生成对抗网络的逼真单图像超分辨率, ” 2017 年 IEEE 计算机视觉和模式识别会议 (CVPR),2017 年 7 月。

[34] P. Arbelaez,M. Maire,C. Fowlkes 和 J. Malik: “轮廓检测和分层图像分割” 。 IEEE 模式分析和机器学习交易 (TPAMI),33(5):898-916,2011 年 5 月。

[35] L. Cormack HR Sheikh,Z.Wang 和 AC Bovik, “实时图像质量评估数据库第 2 版” ,2014 年。

[36] Fortin, FA, De Rainville, FM, Gardner, MA, Parizeau, M., Gagné, C.: “DEAP:进化算法变得简单。” J.马赫.学习.水库。 13, 2171-2175 (2012)。

[37] A. Paszke 等人: “Pytorch:一种命令式的高性能深度学习库” ,Proc.进阶神经信息过程.系统,2019 年, 第 8026-8037 页。