






AutoNAS:用于高光谱解混的自动神经架构搜索

朱涵 , 学生会会员, IEEE, Danfeng Hong,  高级会员, IEEE,

高连茹 , 高级会员, IEEE, Bing Zhang,  院士, IEEE,

黄敏和 Jocelyn Chanussot , 院士, IEEE

摘要 :由于强大的自动表示能力,深度学习 (DL)技术在高光谱解混 (HU)方面取得了重大突破和进步。

在 DL 方法中,自动编码器 (AE) 已成为一种广泛使用且有前途的网络架构。然而,这些基于 AE 的方法严重依赖于手动设计,可能不适合特定的数据集。为了更智能地分解高光谱图像,我们提出了一种 HU 自动神经架构搜索模型,简称 AutoNAS,通过同时考虑通道配置和卷积核来确定最佳网络架构。在AutoNAS中,首先设计了**基于高光谱图像的自监督训练机制来生成超网的训练样本。然后,通过在训练阶段对超网权重应用不同的仿射变换,采用仿射参数共享策略,从而能够找到最佳信道配置。**此外,在获得的通道配置的基础上,将具有额外计算约束的进化算法引入网络,通过评估超网中不同架构的解混结果来实现灵活的卷积核搜索。在四个高光谱数据集上进行的大量实验证明了与几种最先进的分解算法相比,所提出的AutoNAS 的有效性和优越性。

索引词- 仿射参数共享 (APS)、自动编码器 (AE)、深度学习 (DL)、进化算法 (EA)、超光谱分解 (HU)、神经结构搜索 (NAS)。

手稿于 2022 年 3 月 8 日收到; 2022 年 4 月 26 日和 2022 年 5 月 20 日修订; 2022 年 6 月 14 日接受。出版日期 2022 年 6 月 27 日;当前版本的日期为 2022 年 7 月 7 日。这项工作部分由中国国家自然科学基金资助,资助号为 62161160336 和资助金 42030111,部分由 MIAI@Grenoble Alpes 资助,资助号为 ANR-19-P3IA 0003,部分由安盛研究基金。(通讯作者:高连茹。)

朱涵 (中国科学院数字地球科学重点实验室、航天信息研究所、可持续发展目标大数据国际研究中心, 北京 100094, 资源与环境学院), 中国科学院大学, 北京 100049 (e-mail: hanzhu19@mails.ucas.ac.cn)。

Danfeng Hong, Lianru Gao, and Min Huang 来自中国科学院航天信息研究所计算光学成像技术重点实验室,北京 100094 (电子邮件: hongdf@aircas.ac.cn; gaolr@aircas.ac.cn; huangmin@aircas.ac.cn)。

张兵,中国科学院航天信息研究所,北京 100094,中国科学院大学资源与环境学院,北京 100049 (e-mail: zb@radi.ac.cn)。

Jocelyn Chanussot 是 GIPSA-Lab, CNRS, Grenoble Institute of Technology (Grenoble INP), Université Grenoble Alpes, 38000 Grenoble, France, 以及航空航天信息研究所, 中国科学院, 北京 100094, 中国 (e-邮箱: jocelyn@hi.is)。

数字对象标识符 10.1109/TGRS.2022.3186480

1558-0644 © 2022 IEEE。允许个人使用,但再版/再分发需要 IEEE 许可。
有关详细信息,请参阅 <https://www.ieee.org/publications/rights/index.html>。

一、引言

由于丰富的光谱信息和高光谱分辨率,高光谱图像**受益** (HSI)在地球观测和遥感领域受到广泛关注,如降维[1]-[3],土地覆盖分类[4]-[6],以及目标检测[7]-[9],可以有效地检测和识别各种地面物体[10]。然而,由于传感器的空间分辨率有限,单个像素通常是场景中多种材料的混合,不可避免地降低了高级数据处理的性能[11]。高光谱分解 (HU) 旨在通过将混合像素分离为光谱特征 (端元)及其相应分数 (丰度) [12]-[14] 的组合来解决此问题。

解混方法目前依赖两种类型的混合模型来解释入射光与材料之间的相互作用机制:线性混合模型 (LMM)和非线性混合模型 (NLMM) [15]。LMM 假设入射光与一种材料之间存在单一相互作用,并且由于其简单性和灵活性在过去几十年中得到了广泛应用。然而,LMM 无法考虑真实世界遥感场景中不同材料之间的多次散射,例如紧密的矿物混合物和植被冠层,这会导致可观察到的分解误差 [16]、[17]。为了解决复杂的非线性相互作用,已经提出了许多 NLMMs 来模拟不同阶次的散射效应并产生更准确的解混结果 [18]-[23],而在实践中很难获得用于构建 NLMM 的阶次特征的先验知识 [24]。一旦采用的NLMM不适用于实际场景,估计端元和丰度结果的准确性将大大降低。

因此,有必要找到一种更通用的方法来解混 HSI。

受模式识别和计算机视觉中深度学习 (DL) 技术快速发展的启发,在 HSI 分析领域已经开发了大量基于学习的方法,例如分类 [25]、特征学习 [26]、[27] 和数据融合 [28]、[29]。DL 网络本质上是由许多基本模块堆叠而成的多层算术结构,可以学习数据的复杂非线性映射关系。由于其强大的学习和数据拟合能力,深度学习已被少数作品广泛用于解决分离问题。

这些 DL 网络主要包括生成对抗网络 (GAN) [30]、自动编码器 (AE) [31]、卷积神经网络 (CNN) [32] 和递归神经网络 (RNN) [33]。具体来说,GAN 可以在不知道输入数据的概率分布的情况下生成具有特定分布的数据样本。根据这一专业,Tang等人。 [34] 引入 GAN 生成具有不同数据集分布的训练样本进行网络训练,可以在未知的非线性场景中表现出有竞争力的性能。 HU 感兴趣的下一个架构是 AE,它已经成为探索最多的网络架构,因为它可以自动学习隐藏表示并很好地重建数据。通过对编码器部分施加非负性、和为一或稀疏性约束,基于 AE 的方法可以提供优于传统方法的良好分解结果 [35]。此外,为了整合来自 HSI 的空间信息,Zhang等人。 [36] 首先提出了深度 CNN 解混方法,证明了 CNN 在解混任务中的潜力。洪等。 [37]首次提出了一种像素级和补丁级自监督光谱解混方法,在没有任何地面实况 (GT)信息的情况下有效地提高了解混性能。然而,基于 CNN 的方法仅考虑 HSI 的局部信息,而未能从光谱维度探索内在特性,例如波段间可变性和光谱相关信息。尽管上述 DL 方法取得了良好的解混性能,但它们大多依赖人类专家来设计网络架构。在这种情况下,会消耗大量的设计时间,而且采用的架构不一定是最优的。

神经架构搜索 (NAS)作为自动化机器学习的一项基本任务,旨在以自动化的方式设计具有最佳性能的网络架构。

根据不同的搜索策略,目前的 NAS 方法大致可以分为三类:梯度下降 (GD)、强化学习 (RL)和进化算法 (EA)[38]。随着对架构性能的需求越来越大,依赖人工设计的架构很难满足要求。特别是对于更复杂的遥感数据集,不同网络架构提取的对象特征通常差异很大。

如果在手工架构中忽略了一些高级特征,将对最终识别精度产生很大影响 [39]。 NAS的出现解决了这个痛点,大量的NAS研究已经应用于遥感领域。静等。 [40] 提出了一种基于 GD 的 NAS 遥感图像场景分类方法,并采用边缘归一化使架构搜索更加高效。为了控制网络架构的复杂性,提出了一种基于 EA 的多目标场景分类 NAS 方法,以平衡网络性能和计算效率 [41]。在 [42] 中,为 LiDAR 数据分类设计了一种基于 GD 的自动 CNN 方法,并引入了改进的带有学生 t 分布的标签平滑,以进一步减轻过度拟合问题。米歇尔等人。 [43] 提出了一种用于高光谱波段选择的新策略梯度搜索策略,产生了令人满意的结果。张等。 [44] 采用了基于细胞的 CNN

在高光谱图像分类任务中采用粒子群优化的架构搜索方法,与基于 GD 的方法相比,它能够获得全局最优架构。然而,这些现有的 NAS 方法倾向于搜索网络连接和卷积核,而不是通道数。事实上,搜索信道数量也很重要,因为信道配置直接影响网络在资源受限平台上的承受能力 [45]。例如,在单个全连接层或卷积层中,每秒浮点运算 (FLOPS) 随输出通道线性增加。因此,应该在现有 NAS方法的基础上考虑寻找最优信道配置。

为了克服上述挑战,我们旨在为 HU 构建一个完整的自动化 NAS 框架,称为 AutoNAS。为此,我们首先生成基于 HSI 的自监督训练集用于网络搜索。然后,提出了一种仿射参数共享 (APS)方法,通过对网络权重应用不同的仿射变换来获得最佳信道配置。在获得的通道配置的基础上,采用基于EA的方法搜索网络卷积核,实现了更灵活的HSI提取。更具体地说,本文的主要贡献如下。

- 1)我们提出了一个用于 HU 任务的自动 NAS 框架,称为 AutoNAS,通过同时考虑通道配置和卷积核来确定最佳网络架构。 AutoNAS能够实现更加自动化和智能化的HU,同时在保持最佳解混性能的同时,大大降低人工成本。
- 2)准备和构建自监督训练集,以辅助后续的NAS方法。目前,NAS 方法的训练基本上以监督方法为主,但由于真实测量的困难,很难在 HU 中获取 GT 信息。通过模型驱动方法提取端元并计算它们在 HSI 中的丰度,我们可以避免 GT 获取并使搜索网络能够学习有效的映射关系。

- 3)设计了APS方法来搜索经典的基于AE的解混框架中的通道数。

NAS 方法通常采用参数共享技术来减少冗余训练,但高层参数共享可能会降低网络对不同体系结构的区分。 APS 能够动态调整高效训练和架构区分之间的权衡,使整个搜索过程达到最佳性能。据我们所知,这是第一次探索 HU 任务的频道搜索自动设计。

- 4) 定制了具有附加计算约束的基于 EA 的方法,以获得灵活准确的卷积核解。此外,

同时优化了网络精度和计算复杂度。

本文的其余部分组织如下。相关研究工作在第二节介绍。拟议的 AutoNAS 框架在第三节中介绍。第四节描述了本研究中四个高光谱数据集的广泛实验。第五节总结了讨论和我们的结论。

二.相关研究工作

A. 基于 AE 的解混网络

AE 解混网络可以被视

为一种典型的数据驱动的无监督方式。它可以通过自动学习隐藏的表示（例如,丰度）并用相应的基础（例如,端元）重建数据来实现理想的性能[46]。

一般来说,基于AE的解混方法的目标函数是最小化不同测量形式下的重建误差,例如均方误差（mse）、光谱角距离（SAD)和光谱信息散度（SID）。同时,对隐藏表示层施加丰度的非负约束和求和约束,以促进 AE 分解网络的训练 [47]。

此外,为了满足各种功能需求,对AE分离框架进行了一系列改进。例如,已经提出了堆叠非负稀疏和去噪 AE 分离方法来解决异常值和噪声数据的问题 [48]-[50]。在 [51]-[53] 中,CNN 被引入到传统的 AE 解混架构中,通过集成 HSI 的空间结构进一步提高解混精度。随着不同成像技术的快速发展,可以采用激光雷达作为外部多模态数据来提高解混性能[54]。此外,为了丰富AE解混网络的训练样本特征,设计了许多自监督技术来辅助网络学习并减少信息丢失[55],[56]。对于复杂的非线性场景,Wang等人。 [57] 采用精心设计的解码器架构来估计二阶散射相互作用,证明了基于 AE 的非线性 HU 方法的有效性。此外,开发了多任务学习技术,通过将非线性分解过程分解为不同的任务并利用它们之间的共享信息来提高分解性能[58]。

上述典型AE虽然在HU上取得了很多突破,但主要是在固定的网络架构和连接方式下获取固定的图像信息,不受输入图像特征的驱动。

因此,在本文中,研究了用于基于 AE 的解混网络的 AutoNAS 框架。

二、NAS原理

NAS 由三个主要部分组成:搜索空间、搜索策略和性能评估。图 1 显示了用于 HSI 的 NAS 的总体框架。NAS 通常从一组候选操作开始,采用搜索策略,根据




图 1. HSI 的 NAS 总体框架。

搜索空间。然后,这些候选架构在训练集上从头开始训练,并根据它们在验证集上的表现进行评估。候选架构的评估信息被认为是反馈信息,以调节搜索策略以获得新的候选架构。最终,当搜索终止时,排名靠前的架构被选为最优网络架构。

早期的NAS工作大致遵循上述流程。然而,从头开始训练每个候选架构会消耗大量的计算资源。为了解决 NAS 的这一弱点,参数共享被广泛应用,以利用训练有素的参数来提高搜索效率 [59]。

一种策略是训练一个包含搜索空间中所有候选操作的超网,超网中的共享权重可以加速这些候选架构的训练[60]-[62]。另一种策略是将不同的候选架构视为可训练变量,并通过转移现有成功神经网络的权重来引导它们得到充分训练 [63]-[65]。虽然这两种共享策略在某些场景下可以表现良好,但是搜索过程中参数共享的机制仍然很少被探索。最近,Wang等人。 [66]首先分析了不同参数共享级别对网络搜索的积极和消极影响。得出的结论是,高层共享加快了搜索过程,同时降低了区分不同候选架构的能力。为了平衡搜索效率和架构区分,进一步提出了一种基于仿射变换的通用参数共享方案来实现有效搜索。在 HSI 领域,现有的 NAS 方法不考虑搜索空间中的信道配置,而是应用人工启发式算法 [67],[68]。因此,受仿射变换思想的启发,我们提出了 APS 策略来搜索所提出的 AutoNAS 框架中的通道数,具体介绍在第 III-B 节中进行了说明。

三、HU的AUTONAS框架

在本节中,我们将逐步详细介绍所提出的 AutoNAS 框架的解混过程。图 2 给出了所设计的 AutoNAS 框架的总体流程图,包括搜索最佳基于 AE 的解混架构的四个过程:数据和搜索空间的构建、基于 APS 的信道搜索方法、基于 EA 的核搜索方法和解混绩效评估。

A.数据和搜索空间的构建

由于HU中缺少GT,通过该方法设计并生成了一系列训练和验证数据

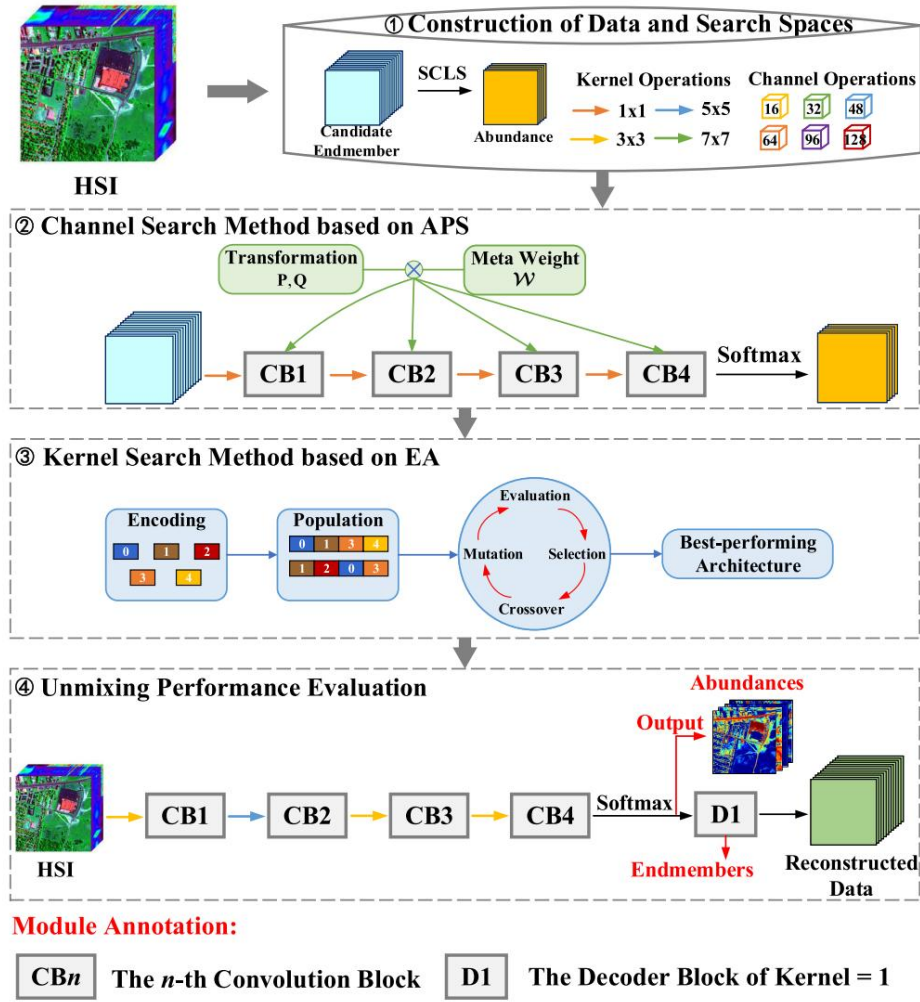


图 2. 拟议的 AutoNAS 框架的总体流程图。

我们之前的工作[55]。具体来说,首先将原始 HSI 划分为一些子集,并在每个子集中应用顶点分量分析 (VCA) [69] 以提取一定数量的候选端元,表示为 $S1 \in RL \times K$, 具有 L 个波段和 K 个候选端元。通过经典的基于 LMM 的方法,例如缩放约束最小二乘法 (SCLS)[70],获得具有 S 个端元类别的相应丰度 $A1 \in RS \times K$ 。通过学习候选端元与其丰度的映射关系,超网得到了充分的训练,有助于后续在验证集上获得最优架构。本质上,这种自监督训练策略可以达到与考虑原始 HSI 和真实丰度的策略类似的效果。优点是避免额外的信息收集,有效解决 HU 中训练样本少的问题。

C 被设置为 {16, 32, 48, 64, 96, 128}。注意,在搜索过程中采用了基于块的编码空间,称为卷积块,其中将各种类型的不同层组合在一起作为搜索空间的基本单元。卷积块依次包括整流线性单元 (ReLU)、卷积和批量归一化 (BN)。基于块的编码空间的优点是参数的数量大大减少,因此,搜索网络可以有更好的性能。

B. 基于 APS 的频道搜索方法

通道搜索方法旨在找到网络每一层中的最佳通道数。这里,采用参数共享方案通过将整个搜索空间编码到单个超网中来降低计算成本,并且所有候选架构在训练期间由超网的网络权重 W 共享。然后,根据验证集上的性能排名确定最佳通道。频道搜索问题可以表述为

拟议的 AutoNAS 中的搜索空间包含两部分:内核操作和通道操作。由于大多数现有的 AE 解混方法都是单路径架构,因此我们在本文中不考虑搜索网络连接。内核操作包括四种可能的操作: 1×1 卷积、 3×3 卷积、 5×5 卷积和 7×7 卷积,以及通道操作

$$W^* = \arg \min_W L_{\text{train}}(f(c1, c2, \dots, cl; W)) \quad \text{st } B(W) \leq B \quad (1)$$

$$\underset{c_1, c_2, \dots, c_l}{*} \text{Lval}(f(c_1, c_2, \dots, c_l; W)) = \arg \min \quad (2)$$

其中Ltrain和Lval分别表示训练和验证损失,例如候选端元的估计丰度 \hat{A} 和真实丰度 A_1 之间的mse。f表示信道搜索网络, (c_1, c_2, \dots, c_l) 表示具有l层的信道决策。B(W)是网络成本函数(即FLOPS), B是计算约束。

然而,最佳网络权重 W^* 不一定保证可以在验证集上有效区分不同的候选架构,因为这些候选架构可能没有得到公平和充分的训练 [65]。

为了在有效训练和体系结构区分之间取得更好的平衡,将 APS 用于信道搜索方法。具体地,假设 c_{in} 和 c_{out} 分别为第 l 个卷积层的输入输出通道,网络权值 $W_{c_{out}}$, $c_{in} \in R_{c_{out}} \times c_{in} \times m \times m$ 通过仿射变换表示为

$$W_{\text{cout,cin}} = Q_{\text{coutT}} \times 2 W \times 1 P_{\text{cin}} \quad (3)$$

其中 \times 表示n模矩阵乘积[71]。 $P_{cin} = [p_1, \dots, p_{cin}] \in R^{c \times cin}$ 和 $Q_{cout} = [q_1, \dots, q_{cout}] \in R^{c \times cout}$ ($c \geq cin, cout$)都是标准的半正交变换矩阵。 $W \in R^{c \times c \times m \times m}$ 是作为共享参数池的元权重,服从标准正态分布,其中 c 和 m 分别表示过滤器的数量和内核大小。

参数共享的级别被计算为不同网络之间的互协方差矩阵的 Frobenius 范数

权重 w_{ji} 和 $w^{j,i}$ ，这是由

$$Lp = Cov W_{j,i}, W_{j,i}^A, \wedge^i$$

$$= \sum_{x=1}^n \sum_{y=1}^n x^A y^A = 1$$

$$F$$

$$E W_{j,i}, y, x W_{j,i}^A, y^A, x^A - E W_{j,i}, y, x E W_{j,i}, y^A, x^A$$

$$(4)$$

其中 $\text{Conv}(\cdot)$ 和 $E(\cdot)$ 分别表示网络参数的交叉协方差和期望的函数值。由于 P 和 Q 中的元素都是标准正交基, 式(4)中的第二项可以计算为

$$\begin{aligned} E W_{j,i} &= E q_{y-x} & \text{吨} & W p x = q y & \text{吨} & E(W) p x = 0 \quad (5) \\ E W_{j,i} y^{\wedge} x &= E q y^{\wedge} & \text{吨} & W p x^{\wedge} = q y^{\wedge} & \text{吨} & E(W) p x^{\wedge} = 0. \quad (6) \end{aligned}$$

我们进一步改写 (4) 如下:

[illegible]

随着 L_p 的增加,信道搜索网络可以实现更高效的搜索,但不同候选之间会产生更大的耦合,导致验证阶段的判别性能较低。因此,APS的目标函数被设计为包含两个阶段的频道搜索。在第一阶段,我们通过使用单位矩阵初始化 P 和 Q 来最大化 L_p 以加快搜索过程,并且LSTM控制器 $\pi(\theta)$ 均匀采样通道决策 $\mathbf{c} = [c_1, \dots, c_L]$ 。 $\pi(\theta)$ 在固定参数 θ 下。在此过程中,通过最小化网络训练的mse损失来优化 W ,写为

$$\text{列车} = \frac{\text{钾}}{\text{钾}} \frac{(a^{1k} - a^{1k})^{2k}}{\text{我} = 1} \quad (8)$$

其中 $1 \leq k \leq A_1$ 表示 A 中的第 k 个丰度向量, a_{1k} 和 A_1 分别。

在第二阶段,我们通过优化P和Q逐渐减少Lp以防止 can didates 耦合,由下式给出

$$\text{列车}=\frac{\text{钾}^{27}}{\text{钾}}\left(a^{\wedge}1k-a1k\right)^{27}+\lambda\left(Qj\right)\text{TQj}2\text{F}\text{我,j}\text{i,j}\cdot\left(Pi\right)^{\text{T}Pi2}\text{F,i,l,j,i,j}\in C\left(9\right)$$

其中 λ 是用于控制参数共享转换的权衡参数。

同时,通道搜索模型在验证集上的评估信息被反馈给 LSTM 控制器,控制器参数 θ 通过使用策略梯度优化 [72] 最大化奖励函数 $R(ac)$ 的期望来更新。具体来说,奖励函数 $R(ac)$ 被设计为

$$R(ac) = \frac{\frac{2\pi}{\text{左心室}(\text{交流})}}{\frac{Z(\text{交流})}{Z}} \times \eta \quad (10)$$

其中 $L_{val}(ac)$ 表示不同通道决策下 A^* 和 A_1 之间的mse验证损失, η 是权重因子,定义为

$$\eta = \begin{cases} \alpha, & \text{如果 } B(ac) \leq B\beta, \\ \text{否则} \end{cases} \quad (11)$$

其中 α 和 β 是 FLOPS 约束的系数。请注意, 我们可选择地最小化训练集上的 L_{train} 以优化验证集上的信道搜索网络权重 W 和参数共享级别 L_p 和 L_{val} 以优化由 LSTM 控制信道决策 a_c 。当达到最大步数或控制器参数 θ 收敛时, 信道搜索网络停止训练, 最优信道决策 a^*

$c = (c_1, c_2, \dots, c_l)$ 是基于最小验证误差的准则最终得到的。

C. 基于EA的内核搜索方法

由于 EA 对局部极小值的不敏感特性,EA 被广泛用于解决复杂的非凸优化问题 [73]。这里,本文采用了 EA 中的遗传算法,因为它更适合

用于求解离散搜索问题,计算量相对较小。首先,搜索空间被编码为一个数字序列,例如“0”表示具有 1×1 核的卷积块,“3”表示具有 7×7 核的卷积块。基于编码数字,类似于信道搜索,我们随机生成一些l层的种群结构,并将它们发送到超网进行训练。

然后,采用 EA 通过评估不同候选者在验证集上的表现来搜索最佳架构。最优核搜索执行如下

$$v^* = \arg \min_v Lval(f(v,WV))$$

(12)

其中 v 和 WV 分别表示搜索核和最优超网权重, Lval表示A ^和A1之间的 mse。

同时,应用了几种遗传操作来制造与其父母不同的后代。例如,交叉操作使候选人混合父母的信息以形成各种类似父母的后代。变异操作改变了候选者的随机基因,使其不同于他们的父母。这里,为了考虑搜索阶段的计算约束,引入一种新的适应度策略来提高模型的可靠性,其写法如下:

$$F_i = \frac{w_1 + w_2(B - B(v_i))}{Lval(v_i) w_1}, \text{如果 } B(v_i) \leq B$$

$$Lval(v_i), \text{否则}$$

(13)

其中w1和w2是平衡验证损失和计算约束的权重系数,根据经验分别设置为 0.01 和 0.02。选择适应度较高的种群作为父代,重复以下交叉和变异操作以生成满足给定计算约束的足够多的新候选种群。所提出的基于 EA 的核搜索方法的具体流程图如算法 1 所示。

D. 分解性能评估

根据获得的网络架构,构建了一个简单的基于 AE 的解混网络来解决解混问题。在这里,我们的方法的混合假设遵循 LMM,可以表示为

$$Y = SA + N \text{ st } 1T$$

$$A = 1T_{\text{st}}, \text{ } A \geq 0, S \geq 0$$

(14)

其中 $Y \in \mathbb{R}^L \times N$ 是观测到的具有L波段和N像素的高光谱数据。 $S \in \mathbb{R}^L \times S$ 是具有S个端元类别的端元矩阵, $A \in \mathbb{R}^S \times N$ 是对应的丰度矩阵。 $N \in \mathbb{R}^L \times N$ 表示残差矩阵,包含上瘾噪声和其他误差。此外, A 满足丰度非负约束 (ANC) 和丰度求和约束 (ASC)。 S 还需要满足端元非负约束 (ENC)。

$$1T_{\text{st}} = [1, \dots, 1] \in \mathbb{R}^1 \times S \text{ 是一个向量,强制每个像素的丰度之和为1。}$$

算法 1基于 EA 的 HU 核搜索输入:验证集Dval,迭代次数Iter,种群大小O,超网权重WV,计算约束B,变异概率prob,交叉概率cros,返回架构vbest。

输出:架构约束下损失最小的架构。

```
1: P1 ← I 初始化人口(O, B); 2: T ← O/2,
M ← O/2,概率←0.1; 3: while i < Iter do
Lossi ← I nference(WV, Pi, Dval); 5: F ←
4: ComputeFitness(Lossi, Pi); 6: T opk
← RankFitness(F); Pcrossover ← Crossover(T
opk, T, B); Pmutation ← Mutation(T opk,
7: M, prob, B); Pi+1 ← Pcrossover U
8: Pmutation ; 10: end while 11: vbest ← T opk中
9: 的最小损失; 12:返回vbest ;
```

基于 AE 的解混合网络的训练是通过最小化输入数据Y和重建数据Y ^ 之间的 SAD 目标函数来实现的,该函数由下式给出

$$LR = \frac{\sum_{i=1}^N \frac{y_i^T y_i}{\|y_i\|^2}}{\sum_{i=1}^N 1}$$

(15)

其中 y_i 和 y_i^T 分别表示Y和Y ^ 中的第 i 个向量。

由于 softmax 函数不能产生稀疏的 abun 舞蹈,因此通过引入L1/2正则化对编码器输出强制执行稀疏约束。 L1/2正则化表示为

$$Lreg = A \sum_{j=1}^N \frac{1}{2} = \frac{1}{2} \sum_{j=1}^N |A_{ij}|$$

(16)

最后,基于AE的解混网络的整体损失可以表述为

$$LAE = LR + \gamma Lreg$$

(17)

其中 γ 是平衡重建约束和稀疏正则化的权衡参数。特定数据集上的 γ 设置是固定的,以确保比较不同网络架构的公平性。

四.实验与分析

在本节中,我们评估了所提出方法在合成和真实高光谱数据集集中的性能,如图 3 所示。采用四种经典和最先进的解混方法来比较所提出的方法,包括NMF -l1/2 [74],具有稀疏性的无约束降噪 AE (uDAS) [50],深度 AE 解混 (DAEU) [47],以及 CNN AE 解混 (CNNAEU) [52]。 [75] 中引用了 GT 端元和 Jasper Ridge 和 Urban 数据的相应丰度。对于天宫一号港数据,由于没有GT,我们只做性能分析,没有进行定量比较。




图 3. 实验中使用的四个高光谱数据集的 RGB 图像。(a) 综合数据。(b) 碧玉岭数据。(c) 城市数据。(d) 天宫一号港口数据。

表一

不同高光谱数据集上 AUTONAS方法的超参数

Phase		Synthetic	Jasper Ridge	Urban	TianGong-1
Channel Search Phase	Number of Layers	4	4	4	4
	Learning Rate of \mathcal{W}	1e-3	1e-3	1e-3	1e-3
	Learning Rate of θ	5e-4	2e-4	2e-4	2e-4
	Weight Decay	3e-4	1e-4	1e-4	1e-4
	Parameter Sharing Parameter λ	1e-6	1e-6	1e-6	1e-6
	FLOPs Coefficient α, β	0, -0.1	0, -0.1	0, -0.1	0, -0.1
	Initial Training Epoch	300	300	300	300
	Max Epoch	500	500	500	500
Kernel Search Phase	Number of Populations O	30	30	30	30
	Number of Top Architectures $Topk$	10	10	10	10
	Mutation Probability $prob$	0.1	0.1	0.1	0.1
	Learning Rate	8e-3	5e-3	5e-3	1e-3
	Weight Decay	5e-4	3e-4	3e-4	1e-4
	Max Epoch	200	200	200	200
Unmixing Evaluation Phase	Learning Rate	3e-3	8e-3	4e-2	8e-3
	Sparsity Regularization γ	7e-3	7e-2	7e-2	7e-2
	Max Epoch	300	500	500	500

A. 实验设置

1) 实现细节:为了公平比较,以下所有实验均在配备 Intel Core i7 和 NVIDIA GTX 1080 Ti 11-GB GPU 的计算机上执行。

端元数S由最小误差高光谱信号识别 (HySime) [76] 确定,初始端元由 VCA 提取用于所有比较方法。候选端元数量设置为2000,其中1500用于训练,500用于验证。

具体来说,训练数据用于训练通道和内核搜索网络,而验证数据用于评估不同候选架构的解混性能以获得最佳通道和内核结果。

采用 Adam 优化器 [77] 在训练阶段更新网络参数, 架构约束采用 $\text{FLOPS} \leq 5 \text{ G}$ 以降低候选架构的计算复杂度。此外, 为了验证最优架构在解混性能评估中的有效性, 超参数在同一数据集集中保持一致。具体的超参数设置如表一所示。

SAD 和根均方误差 (RMSE)。SAD 定义为

$$\text{悲伤} = \frac{\text{2个}}{\text{小唱}} \text{余弦} - 1 \frac{\text{ST}_{\text{,s}} \wedge i}{\text{si } 2 \quad \text{s}^{\wedge} i \quad \text{2个}} \quad (18)$$

其中 s_i 和 s^i 分别表示参考端元和估计端元。

RMSE 定义为

$$\text{均方根误差} = \frac{\sum_{j=1}^n (\hat{a}_j - a_j)^2}{n} \quad (19)$$

中 a_j 分别表示实际丰度和估计的 j 丰度。

此外,卷积层中的 FLOPS 用于评估计算复杂度 [78],由下式给出

$$\text{FLOPS} = 2H_{in}W_{in} \text{cinK2} + 1 \text{ cout} \quad (20)$$

其中Hin和Win分别表示输入数据的高度和宽度，Kc表示卷积的核大小。请注意，采用GFLOPS作为计算指标，并且 $GFLOPS = 109 \times FLOPS$ 。

2) Evaluation Metrics:在实验中,利用两个评估指标来评估端元估计的精度和对应的丰度,包括




图 4. 由不同算法获得的合成数据中五种物质的丰度图。

表二

AUTONAS的最佳搜索架构		
Dataset	Optimal Channel	Optimal Kernel
Synthetic	[16, 128, 96, 5]	$1 \times 1, 1 \times 1, 1 \times 1, 3 \times 3$
Jasper Ridge	[128, 16, 48, 4]	$1 \times 1, 1 \times 1, 1 \times 1, 7 \times 7$
Urban	[96, 16, 32, 4]	$3 \times 3, 5 \times 5, 3 \times 3, 3 \times 3$
TianGong-1 Port	[48, 32, 96, 6]	$1 \times 1, 3 \times 3, 1 \times 1, 1 \times 1$

表三

前四名搜索频道的表现 对于合成数据上的AUTONAS				
Channel	Loss	RMSE	SAD	GFLOPs
[16, 128, 96, 5]	0.0621	0.0307	0.0113	0.04
[16, 96, 128, 5]	0.0773	0.0308	0.0193	0.04
[64, 128, 96, 5]	0.0770	0.0355	0.0129	1.72
[128, 64, 128, 5]	0.0811	0.0373	0.0166	3.44

表IV

前四名搜索内核的性能 对于合成数据上的AUTONAS				
Kernel	Loss	RMSE	SAD	GFLOPs
$1 \times 1, 1 \times 1, 1 \times 1, 1 \times 3$	0.0560	0.0299	0.0110	0.89
$1 \times 1, 5 \times 5, 1 \times 1, 5 \times 5$	0.0583	0.0309	0.0126	3.16
$1 \times 1, 5 \times 5, 1 \times 1, 7 \times 7$	0.0597	0.0320	0.0217	3.62
$3 \times 3, 1 \times 1, 1 \times 1, 3 \times 3$	0.0614	0.0324	0.0227	1.83




图 5. 合成数据中不同解混算法提取的端元比较。(a) 材料 1、(b) 材料 2、(c) 材料 3、(d) 材料 4、(e) 材料 5。

B. 合成数据实验

合成数据已广泛应用于评估解混性能 [70]、[79]–[81]。它由五个端元组成

参考了美国地质调查局 400 至 2500 nm 波长范围内的 224 个波段以及相应的 200 × 200 像素大小的丰度图。丰度遵循高斯分布,旨在满足 ANC 和 ASC。请注意,合成数据是基于 LMM 生成的,同时通过添加 [0.75,1.25] 范围内的比例因子来考虑光谱可变性。此外,图像中还加入了 20 dB 的高斯白噪声,以模拟复杂的高光谱场景。

表五
不同方法在合成数据上的RMSE和SAD方面的定量性能比较。最佳结果以粗体显示。

Metric	NMF- $l_{1/2}$	uDAS	DAEU	CNNAEU	AutoNAS-Channel	AutoNAS-Kernel
RMSE	0.1168	0.0672	0.0676	0.0487	0.0307	0.0299
SAD	0.0531	0.0208	0.0259	0.0205	0.0113	0.0110
Running time (s)	181.40	58.33	77.98	129.26	6459.83	190.15

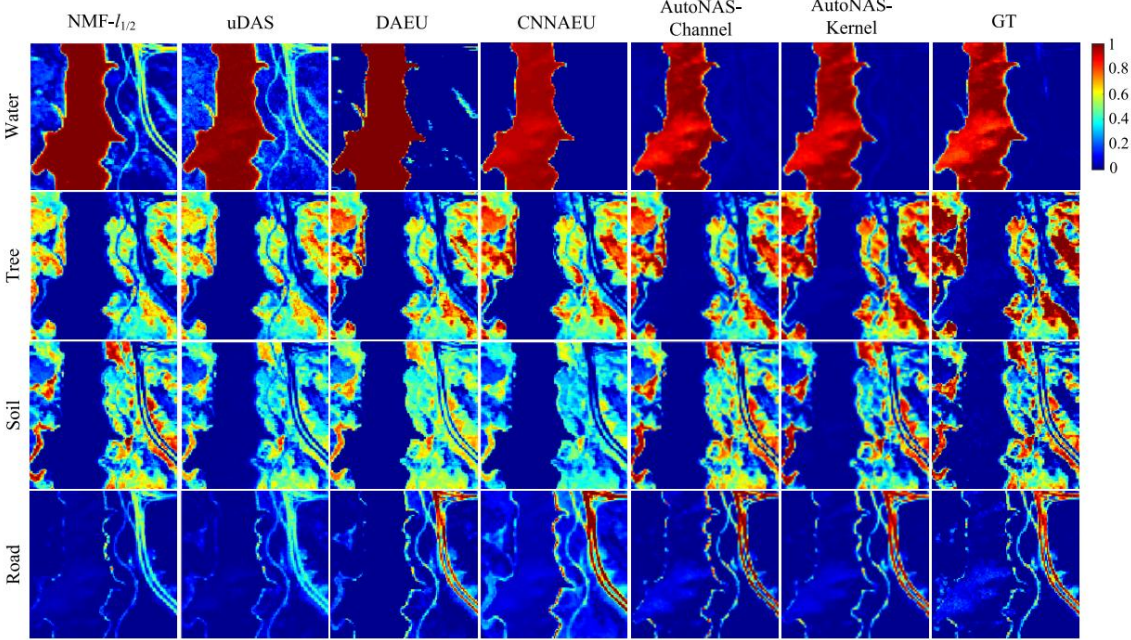


图 6. 通过不同算法获得的贾斯珀岭数据中水、树木、土壤和道路的丰度图。

表 II 列出了 AutoNAS 在四个数据集上的最佳搜索架构,表 III 和表 IV 报告了合成数据搜索过程中的具体细节。基于最小验证损失选择最佳架构。从表 III和表IV可以看出,前四名搜索到的架构基本可以满足良好的unmixing趋势,验证损失减少,表明搜索网络得到了有效的训练,可以实现准确的架构判别。

表 V 和图.图 4 和图 5 分别显示了合成数据的定量性能结果、相应的丰度图和提取的端元比较。图中的 AutoNAS-Channel 和 AutoNAS-Kernel。图4和图5分别表示各层卷积核为1时最优信道搜索的解混结果和最优信道固定时最优核搜索的解混结果。很明显,基于 DL 的解混方法可以获得比传统方法 NMF-l1/2 更小的 RMSE 和 SAD 结果,并且提取的 AutoNAS 端元签名与 GT 基本匹配良好。通道搜索后提出的 AutoNAS 可以实现优于其他基于 DL 的解混方法的性能,这说明人类专家设计的基于 DL 的方法不受高光谱数据特性的驱动,并且提出的基于 DL 的通道搜索方法APS可以

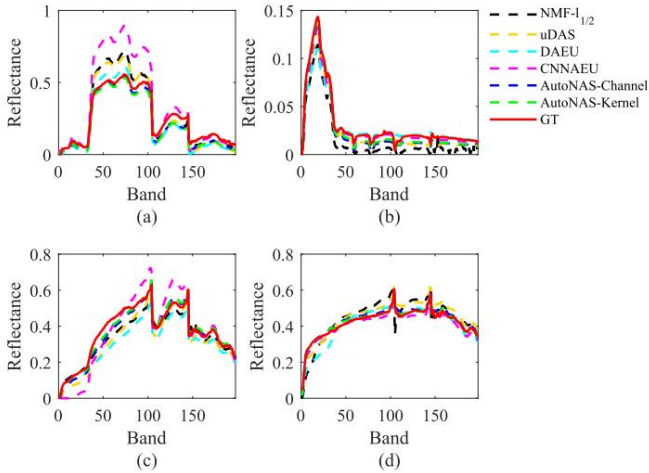


图 7. Jasper Ridge 数据中不同解混算法的提取端元比较。(一)一颗树。(二)水。(c) 土壤。(d) 道路。

自动搜索最优架构。此外,AutoNAS 提取的内核搜索结果也优于通道搜索结果,证明了所提出的 EA 搜索方法的有效性。在计算性能方面,相比于AutoNAS, AutoNAS需要一定的计算资源来实现自动搜索。

表六
不同方法在JASPER RIDGE数据上的RMSE和SAD方面的定量性能比较。最佳结果以粗体显示_

Metric	NMF- $l_{1/2}$	uDAS	DAEU	CNNAEU	AutoNAS-Channel	AutoNAS-Kernel
RMSE	0.1554	0.1510	0.1156	0.1130	0.0685	0.0447
SAD	0.1842	0.1153	0.1270	0.0892	0.0808	0.0716
Running time (s)	27.76	11.98	13.36	25.42	1178.59	55.97

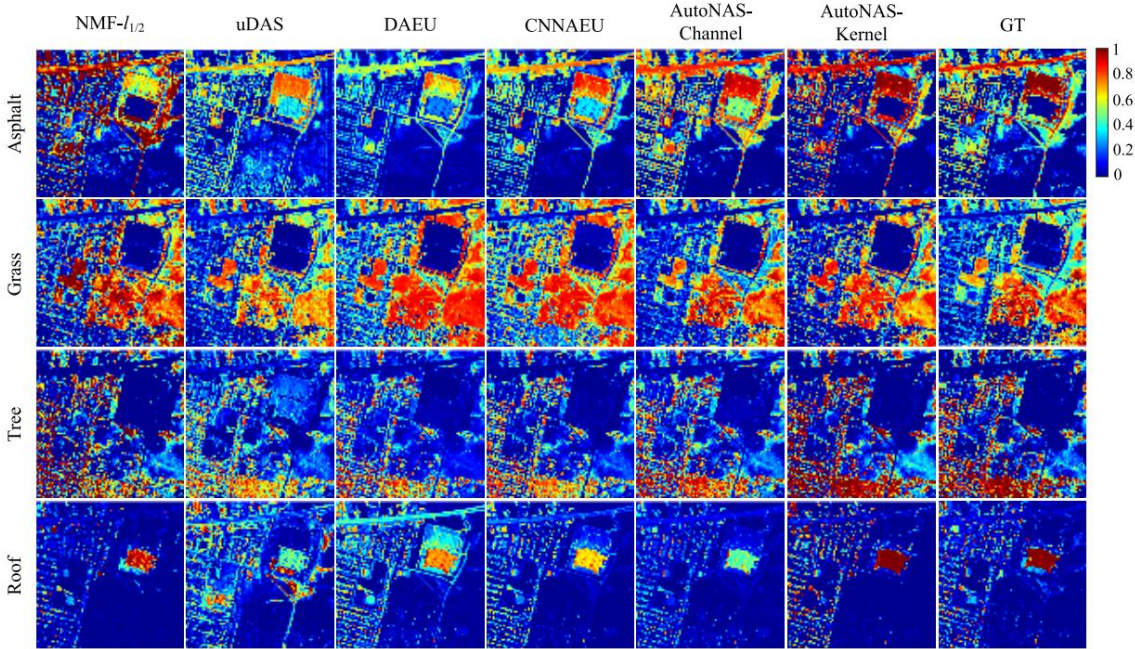


图 8. 通过不同算法获得的 Urban 数据中沥青、草地、树木和屋顶的丰度图。

其他具有固定架构的解混方法,因为它包含不同候选架构的训练和评估过程。总体而言,AutoNAS 中自动搜索技术的计算成本比手动设计技术更高效、更合理。

C. 真实数据实验 1) AVIRIS Jasper

Ridge 图像: Jasper Ridge 数据由喷气推进实验室 (JPL) 的机载可见光/红外成像光谱仪 (AVIRIS) 捕获。原始图像包含 512×614 像素和 224 个波段,范围从 380 到 2500 nm。在这里,我们采用大小为 100×100 像素的子图像来评估分离性能。在去除受大气影响和水汽影响的通道后,使用了 198 个通道。

在这个研究场景中,研究了四个主要端元,即#1 水、#2 树、#3 土壤和#4 路。

表 VI 和图 6 显示了不同方法的定量性能和 Jasper Ridge 数据上估计的丰度图。总体而言,AutoNAS 在 RMSE 和 SAD 方面可以获得比其他基于 DL 的手工方法更好的竞争结果,证明了其优越性和有效性。出于说明目的,AutoNAS 和 GT 之间提取的端元比较如图 7 所示。显然,AutoNAS2 提取的端元签名优于 AutoNAS,




图 9. Urban 数据中不同解混算法的提取端元比较。(a) 沥青。(二)草。(c) 树。(d) 屋顶。

进一步说明整个AutoNAS框架可以获得更准确可靠的解混结果。此外,与其他比较方法相比,uDAS 可以实现更好的计算效率。由于元权重和变换参数的训练,建议的AutoNAS在信道搜索阶段花费了更多的时间,但基本上是

表七

不同方法在城市数据上RMSE和SAD的定量性能比较.最佳结果以粗体显示_

Metric	NMF- $l_{1/2}$	uDAS	DAEU	CNNAEU	AutoNAS-Channel	AutoNAS-Kernel
RMSE	0.2368	0.2197	0.1602	0.1468	0.1071	0.1064
SAD	0.2544	0.2004	0.1984	0.1653	0.1835	0.0509
Running time (s)	382.85	77.98	109.94	188.63	16375.74	188.61

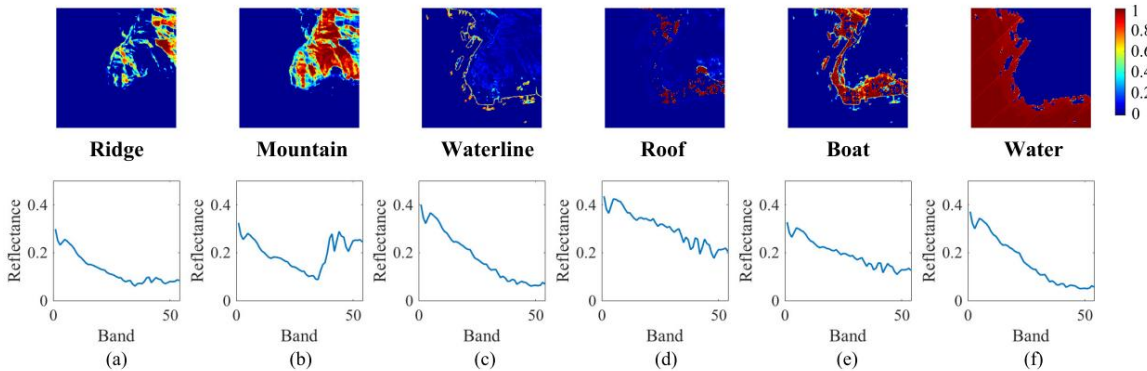


图 10. 天宫一号港口数据中所提出的 AutoNAS 提取的丰度图和相应的端元。(a) 山脊。(二)山。(c) 吃水线。(d) 屋顶。(e) 船。(f) 水。

控制在20分钟以内,说明在小数据集上的耗时还是比较满意的。

2)HYDICE Urban Image :城市数据是通过高光谱数字图像采集实验 (HYDICE)传感器获得的.该图像为 307×307 像素,具有 210 个波段,涵盖 400 至 2500 nm 的光谱通道.由于水汽和大气的影 响,只剩下162个波段.实验选取沥青、草地、树木和屋顶作为主要端元。

图 8 可视化了不同方法在 Urban 数据上的丰度图,相应的定量结果见表 VII.从表 VII 可以看出,基于 DL 的解混方法可以获得比传统方法更准确的端元和丰度结果.此外,相应的丰度图更可分离,更接近GT.与基于DL的方法相比,AutoNAS可以充分考虑数据的特性来设计最优架构,从而获得更好的解混效果.为了便于说明,提取的 AutoNAS 端成员签名如图 9 所示。

显然,与AutoNAS-Channel相比,AutoNAS Kernel提取的endmember签名更接近GT,这进一步证明了所提出的EA搜索方法可以获得最优的网络架构.此外,可以看出 AutoNAS 在内核搜索阶段花费的时间与 CNNAEU 一样多,证明了在大型数据集上的计算有效性。

3) 天宫一号端口图像:在本节中,我们尝试使用建议的 AutoNAS 研究更复杂的 HU 场景,例如端口.所用HSI采集于2011年9月29日发射的天宫一号卫星,数据预处理包括辐射校正、几何校正和空间裁剪,具体可参考文献[82]。由于缺少GT,仅采用天宫一号数据进行目视对比,不采用

定量评估,以测试所提出的方法在真实场景中的性能.端口图像如图 3 (d)所示,包括 256×256 像素.去除受暗像素和水汽影响的通道后,端口图像中有 54 个波段,覆盖了 400 至 900 nm 的光谱通道.研究了六个主要端元,即#1 山脊、#2 山、#3 水线、#4 屋顶、#5 船和#6 水.图 10 显示了估计的丰度图和所提出的 AutoNAS 提取的相应端元.可以看出,AutoNAS 可以在港口场景中清晰地分离多个端元,结果表明所提方法在实际场景中的潜力。

五.结论

在本文中,提出了一个称为 AutoNAS 的自动 NAS 框架,以智能地找到最适合 HU 任务的基于 AE 的架构.具体来说,拟议的 AutoNAS 同时考虑通道配置和内核.在频道搜索中,APS 旨在通过动态平衡搜索效率和架构区分来实现最佳性能.然后,在获得的最优通道的基础上,采用具有附加计算约束的 EA,通过评估验证集上不同候选者的性能来实现灵活的内核搜索.与人类专家设计的其他几种最先进的基于 DL 的方法相比,使用合成和真实高光谱数据集进行的实验证明了所提出方法的有效性和优越性.此外,AutoNAS可以通过调整不同的FLOPS约束,对计算复杂度提供更细粒度的控制,帮助根据实际需要设计合适的网络架构.未来,我们的目标是将 AutoNAS 扩展到在轨卫星数据处理,并应用于实际问题。

参考

[1] Y. Gao,X. Wang,Y. Cheng 和 Z. Wang,“基于类感知张量邻域图和补丁对齐的高光谱数据降维”, IEEE Trans.神经网络.学习.系统,卷. 26,没有. 8,第 1582–1593 页,2014 年 8 月。

[2] JP Rivera-Caicedo,J. Verrelst,J. Muñoz-Marí,G. Camps-Valls 和 J. Moreno,“用于生物物理变量统计检索的高光谱降维”, ISPRS J. Photogramm.遥感,卷. 132,第 88–101 页,2017 年 10 月。

[3] D. Hong,N. Yokoya,J. Chanussot,J. Xu 和 XX Zhu,“学习在图上传播标签:半监督高光谱降维的迭代多任务回归框架”, ISPRS J.摄影报.遥感,卷. 158,第 35–49 页,2019 年 12 月。

[4] S. Yang,Z. Feng,M. Wang 和 K. Zhang,“用于高光谱图像分类的基于自定进度学习的概率子空间投影”, IEEE 跨.神经网络.学习.系统,卷. 30,没有. 2,第 630–635 页,2018 年 6 月。

[5] D. Hong,N. Yokoya,N. Ge,J. Chanussot 和 XX Zhu,“可学习流形对齐 (LeMA):一种用于土地覆盖和土地利用分类的半监督跨模式学习框架”, ISPRS J. 照片.遥感,卷. 147,第 193–205 页,2019 年 1 月。

[6] D. Hong等人,“更多样化意味着更好:多模态深度学习满足遥感图像分类”, IEEE Trans.地球科学.遥感,卷. 59,没有. 5,第 4340–4354 页,2021 年 5 月。

[7] Q. Du 和 C.-I. Chang,“一种信号分解和干扰消除的高光谱目标检测方法”, IEEE Trans.地球科学.遥感,卷. 42,没有. 4,第 892–906 页,2004 年 4 月。

[8] X. Wu,D. Hong,J. Tian,J. Chanussot,W. Li 和 R. Tao,“ORSIm 检测器:一种使用空间频率通道特征的光学遥感影像中的新型目标检测框架” IEEE 跨.地球科学.遥感,卷. 57,没有. 7,第 5146–5158 页,2019 年 7 月。

[9] X. Wu,D. Hong,J. Chanussot,Y. Xu,R. Tao 和 Y. Wang,“基于傅里叶的旋转不变特征增强_地理空间对象检测的有效框架”, IEEE Geosci.遥感快报,卷. 17,没有. 2,第 302–306 页,2020 年 2 月。

[10] D. Hong等人,“可解释的高光谱人工智能:当非凸建模遇到高光谱遥感时”, IEEE Geosci.遥感杂志,卷. 9,没有. 2,第 52–87 页,2021 年 6 月。

[11] N. Keshava 和 JF Mustard,“频谱分离”, IEEE 信号处理.杂志,卷. 19,没有. 1,第 44–57 页,2002 年 1 月。

[12] N. Dobigeon, J.-Y. Tournet 和 C.-I. Chang,“使用分层贝叶斯模型进行高光谱图像的半监督线性光谱分解”, IEEE Trans.信号处理,卷. 56,没有. 7,第 2684–2695 页,2008 年 7 月。

[13] Y. Zhong,X. Wang,L. Zhao,R. Feng,L. Zhang 和 Y. Xu,“基于稀疏分量分析的高光谱遥感图像盲光谱分离”, ISPRS J. Photogram.遥感,卷. 119,第 49–63 页,2016 年 9 月。

[14] J. Yao,D. Meng,Q. Zhao,W. Cao 和 Z. Xu,“基于非凸稀疏性和非局部平滑度的盲高光谱分解”, IEEE Trans.图像处理,卷. 28,没有. 6,第 2991–3006 页,2019 年 6 月。

[15] JM Bioucas-Dias等人,“高光谱分解概述:基于几何_统计和稀疏回归的方法”, IEEE J. Sel.主题应用.地球观察.遥感,卷. 5,没有. 2,第 354–379 页,2012 年 4 月。

[16] N. Dobigeon, J.-Y. Tournet,C. Richard,JCM Bermudez,S. McLaughlin 和 AO Hero,“高光谱图像的非线性分解:模型和算法”, IEEE 信号处理.杂志,卷. 31,没有. 1,第 82–94 页,2013 年 1 月。

[17] R. Heylen,M. Parente 和 P. Gader,“非线性高光谱分解方法综述”, IEEE J. Sel.主题应用.地球观察.遥感,卷. 7,没有. 6,第 1844–1868 页,2014 年 6 月。

[18] W. Fan,B. Hu,J. Miller 和 M. Li,“用于分析实验室模拟森林高光谱数据的新非线性模型与普通线性模型的比较研究”, Int. J. Remote Sens.,第一卷. 30,没有. 11,第 2951–2962 页,2009 年 6 月。

[19] A. Halimi,Y. Altmann,N. Dobigeon 和 J.-Y. Tournet,“使用广义双线性模型对高光谱图像进行非线性分解”, IEEE 跨.地球科学.遥感,卷. 49,没有. 11,第 4153–4162 页,2011 年 11 月。

[20] G. Licciardi,X. Ceamanos,S. Douté 和 J. Chanussot,“通过应用于高光谱图像的 NLPCA 进行无监督非线性光谱分离”, Proc. IEEE 诠释.地球科学. Remote Sens. Symp., 2012 年 7 月,第 1369–1372 页。

[21] Y. Altmann,A. Halimi,N. Dobigeon 和 J.-Y. Tournet,“使用后非线性混合模型对高光谱图像进行监督非线性光谱分解”, IEEE Trans.图像处理,卷. 21,没有. 6,第 3017–3025 页,2012 年 6 月。

[22] R. Heylen 和 P. Scheunders,“非线性光谱解混的多线性混合模型”, IEEE Trans.地球科学.遥感,卷. 54,没有. 1,第 240–251 页,2016 年 1 月。

[23] M. Tang,B. Zhang,A. Marinoni,L. Gao 和 P. Gamba,“用于高光谱非线性解混的多谐波后非线性混合模型”, IEEE地球科学.遥感快报,卷. 15,没有. 11,第 1765–1769 页,2018 年 11 月。

[24] M. Tang,L. Gao,A. Marinoni,P. Gamba 和 B. Zhang,“在非线性高光谱分解的归一化 P 线性算法中集成空间信息”, IEEE J. Sel.主题应用.地球观察.遥感,卷. 11,没有. 4,第 1179–1190 页,2018 年 4 月。

[25] D. Hong,L. Gao,J. Yao,B. Zhang,A. Plaza 和 J. Chanussot,“用于高光谱图像分类的图卷积网络”, IEEE Trans.地球科学.遥感,卷. 59,没有. 7,第 5966–5978 页,2021 年 7 月。

[26] H. Xu,W. He,L. Zhang 和 H. Zhang,“用于高光谱图像分类的无监督光谱空间语义特征学习”, IEEE Trans.地球科学.遥感,卷. 60,第 1–14 页,2022 年。

[27] D. Hong等人,“SpectralFormer:用变换器重新思考高光谱图像分类”, IEEE Trans.地球科学.遥感,卷. 60,第 1–15 页,2022 年 11 月,doi: [10.1109/TGRS.2021.3130716](https://doi.org/10.1109/TGRS.2021.3130716)。

[28] K. Zheng等人,“具有自适应响应函数学习的耦合卷积神经网络用于无监督高光谱超分辨率”, IEEE Trans.地球科学.遥感,卷. 59,没有. 3,第 2487–2502 页,2021 年 3 月。

[29] J. Yao,D. Hong,J. Chanussot,D. Meng,X. Zhu 和 Z. Xu,“用于无监督高光谱超分辨率的耦合分离网中的交叉注意力”, Proc.欧元.会议.电脑.可见, 2020 年 8 月,第 208–224 页。

[30] D. Hong,J. Yao,D. Meng,Z. Xu 和 J. Chanussot,“多模式 GAN_迈向跨模式高光谱-多光谱图像分割”, IEEE 跨.地球科学.遥感,卷. 59,没有. 6,第 5103–5113 页,2021 年 6 月。

[31] X. Xu,X. Song,T. Li,Z. Shi 和 B. Pan,“通过全局_局部平滑进行高光谱解混的深度自动编码器”, IEEE 跨.地球科学.遥感,卷. 60,第 1–16 页,2022 年,doi: [10.1109/TGRS.2022.3152782](https://doi.org/10.1109/TGRS.2022.3152782)。

[32] Z. Zeng, J. Sun, C. Xu, and H. Wang, “Unknown SAR target identification method based on feature extraction network and KLD–RPA joint discrimination,” Remote Sens., vol. 13,没有.第 15 页2901,2021 年 7 月。

[33] R. Hang,Q. Liu,D. Hong 和 P. Ghamisi,“用于高光谱图像分类的级联递归神经网络”, IEEE Trans.地球科学.遥感,卷. 57,没有. 8,第 5384–5394 页,2019 年 8 月。

[34] M. Tang,Y. Qu 和 H. Qi,“通过生成对抗网络进行高光谱非线性分解”, Proc. IEEE 诠释.地球科学.遥感器 Symp., 2020 年 9 月,第 2404–2407 页。

[35] S. Ozkan,B. Kaya 和 GB Akar,“EndNet:用于端元提取和高光谱解混的稀疏自动编码器网络”, IEEE Trans.地球科学.遥感,卷. 57,没有. 1,第 482–496 页,2019 年 1 月。

[36] X. Zhang,Y. Sun,J. Zhang,P. Wu 和 L. Jiao,“通过深度卷积神经网络进行高光谱分解”, IEEE Geosci.遥感器快报,卷. 15,没有. 11,第 1755–1759 页,2018 年 11 月。

[37] D. Hong等人,“Endmember-guided unmixing network (EGU-Net): A general deep learning framework for self-supervised hyperspectral unmixing”, IEEE Trans.神经网络.学习.系统,抢先体验,2021 年 5 月 28 日,doi: [10.1109/TNNLS.2021.3082289](https://doi.org/10.1109/TNNLS.2021.3082289)。

[38] P. Ren等人,“神经网络搜索的综合调查_挑战和解决方案”, ACM Comput.幸存者,卷. 54,没有. 4,第 1–34 页,2021 年 7 月。

[39] J. Wang,Y. Zhong,Z. Zheng,A. Ma 和 L. Zhang,“RSNet:在识别任务中寻找遥感深度神经网络”, IEEE 跨.地球科学.遥感,卷. 59,没有. 3,第 2520–2534 页,2021 年 3 月。

[40] W. Jing,Q. Ren,J. Zhou 和 H. Song,“AutoRSISC:用于遥感图像场景分类的神经结构自动设计”, 模式识别.快报,卷. 140,第 186–192 页,2020 年 12 月。

[41] A. Ma,Y. Wan,Y. Zhong,J. Wang 和 L. Zhang,“SceneNet:使用多目标神经进化架构搜索的遥感场景分类深度学习网络”, ISPRS J. Photogramm.遥感,卷. 172,第 171–188 页,2021 年 2 月。

[42] H. Xie 和 Y. Chen,“基于自动设计的 CNN 的激光雷达数据分类”, IEEE Geosci.遥感快报,卷. 18,没有. 9,第 1665–1669 页,2020 年 9 月,doi: [10.1109/LGRS.2020.3005209](https://doi.org/10.1109/LGRS.2020.3005209)。

[43] A. Michel,W. Gross,F. Schenkel and W. Middelmann, “深度强化学习框架内的高光谱波段选择”, Proc. IEEE 诠释.地球科学. Remote Sens. Symp., 2020 年 9 月,第 52-55 页。

[44] C. Zhang,X. Liu,G. Wang 和 Z. Cai, “基于粒子群优化的深度学习架构搜索高光谱图像分类”, Proc. IEEE 诠释.地球科学.遥感症状(IGARSS), 2020 年 9 月,第 509-512 页。

[45] J. Yu 和 T. Huang, “AutoSlim:迈向一次性架构搜索对于频道编号”,2019, arXiv:1903.11728。

[46] GA Licciardi 和 FD Frate, “通过神经网络对高光谱数据进行像素分离”, IEEE Trans. 地球科学.遥感,卷. 49,没有. 11,第 4163–4172 页,2011 年 11 月。

[47] B. Palsson,J. Sigurdsson,JR Sveinsson 和 MO Ulfarsson, “使用神经网络自动编码器进行高光谱解混”, IEEE Access,卷. 6,第 25646–25656 页,2018 年。

[48] Y. Su,A. Marinoni,J. Li,J. Plaza 和 P. Gamba, “用于稳健高光谱解混的堆叠非负稀疏自动编码器”, IEEE Geosci. 遥感快报,卷. 15,没有. 9,第 1427–1431 页,2018 年 9 月。

[49] R. Guo,W. Wang 和 H. Qi, “使用自动编码器级联进行高光谱图像分解”, Proc.第 7 届研讨会高光谱图像信号处理,Evol. Remote Sens. (WHISPERS), 2015 年 10 月,第 1-4 页。

[50] Y. Qu 和 H. Qi, “uDAS:一种具有稀疏性的非绑定降噪自动编码器,用于频道解混”, IEEE Trans.地球科学.遥感,卷. 57,没有. 3,第 1698-1712 页,2019 年 3 月。

[51] MM Elkholy,M. Mostafa,HM Ebied 和 MF Tolba, “使用深度卷积自动编码器进行超光谱分离”, Int. J. Remote Sens.,第一卷. 41,没有. 12,第 4799–4819 页,2020 年 3 月。

[52] B. Palsson,MO Ulfarsson 和 JR Sveinsson, “用于光谱-空间高光谱解混的卷积自动编码器”, IEEE Trans. 地球科学.遥感,卷. 59,没有. 1,第 535–549 页,2021 年 1 月。

[53] F. Khajehrayeni 和 H. Ghassemian, “在监督场景中使用深度卷积自动编码器进行高光谱解混”, IEEE J. Sel.主题应用.地球观察.遥感,卷. 13,第 567–576 页,2020 年 2 月。

[54] Z. Han,D. Hong,L. Gao,J. Yao,B. Zhang 和 J. Chanussot, “多模态高光谱分解:注意力网络的见解”, IEEE 跨.地球科学.遥感,卷. 60,第 1-13 页,2022 年。

[55] Z. Han等人, “用于高光谱解混的深度半孪生网络”, IEEE地球科学.遥感快报,卷. 18,没有.第 11 页,1996–2000 年,2021 年 11 月。

[56] L. Gao,Z. Han,D. Hong,B. Zhang 和 J. Chanussot, “CyCU-Net:通过学习级联自动编码器进行循环一致性解混网络”, IEEE Trans.地球科学.遥感,卷. 60,第 1-14 页,2022 年。

[57] M. Wang,M. Zhao,J. Chen 和 S. Rahardja, “通过深度自动编码器网络对高光谱数据进行非线性分解”, IEEE Geosci. 遥感快报,卷. 16,没有. 9,第 1467–1471 页,2019 年 9 月。

[58] Y. Su,X. Xu,J. Li,H. Qi,P. Gamba 和 A. Plaza, “用于双线性高光谱解混的具有多任务学习的深度自动编码器”, IEEE Trans.地球科学.遥感,卷. 59,没有. 10,第 8615–8629 页,2021 年 10 月,doi: [10.1109/TGRS.2020.3041157](https://doi.org/10.1109/TGRS.2020.3041157)。

[59] H. Pham,M. Guan,B. Zoph,Q. Le 和 J. Dean, “通过参数共享进行高效的神经架构搜索”, Proc.第 35 国际会议。马赫.学习。(PMLR), 2018 年 7 月,第 4095–4104 页。

[60] G. Bender,PJ Kindermans,B. Zoph,V. Vasudevan 和 Q. Le, “理解和简化一次性架构搜索”, Proc. 诠释.会议.马赫.学习。(PMLR), 2018 年 7 月,第 550-559 页。

[61] A. Brock,T. Lim,J. Ritchie 和 N. Weston, “SMASH:通过超网络进行一次性模型架构搜索”, Proc. ICLR, 2018 年 2 月,第 1-21 页。

[62] Z. Guo等人, “具有均匀采样的单路径一次性神经架构搜索”, Proc.欧元.会议.电脑。可见。(ECCV), 2020 年 10 月,第 544-560 页。

[63] H. Cai,T. Chen,W. Zhang,Y. Yu 和 J. Wang, “通过网络转换进行高效架构搜索”, Proc. AAAI 会议.神器. Intell.,2018 年 2 月,vol. 32,没有. 1,第 1-8 页。

[64] J. Peng,M. Sun,Z. Zhang,T. Tan 和 J. Yan, “用于对象检测的通道级高效神经架构转换搜索”, Proc.进阶神经信息过程.系统, 2019 年 12 月,第 14290–14299 页。

[65] C. Li等人, “基于知识蒸馏的块式监督神经架构搜索”, Proc. CVPR, 2020 年 6 月,第 1989–1998 页。

[66] J. Wang等人, “重新审视自动神经通道搜索的参数共享”, Proc.进阶神经信息过程.系统,卷. 33,2020 年 12 月,第 5991–6002 页。

[67] Y. Chen,K. Zhu,L. Zhu,X. He,P. Ghamisi 和 JA Benediktsson, “用于高光谱图像分类的卷积神经网络的自动设计”, IEEE Trans.地球科学.遥感,卷. 57,没有. 9,第 7048–7066 页,2019 年 9 月。

[68] X. Liu,C. Zhang,Z. Cai,J. Yang,Z. Zhou 和 X. Gong, “基于连续粒子群优化的深度学习架构搜索高光谱图像分类”, Remote Sens., vol. 13,没有.第 6 页1082,2021 年 3 月。

[69] JMP Nascimento 和 JM Bioucas-Dias, “顶点分量分析:一种分解高光谱数据的快速算法”, IEEE Trans. 地球科学.遥感,卷. 43,没有. 4,第 898–910 页,2005 年 4 月。

[70] D. Hong 和 X. Zhu, “SULoRA:用于高光谱数据分析的低秩属性嵌入子空间分解”, IEEE J. Sel.主题信号处理,卷. 12,没有. 6,第 1351–1363 页,2018 年 12 月。

[71] TG Kolda 和 BW Bader, “张量分解和应用”, 暹罗评论,卷. 51,没有. 3,第 455-500 页,2009 年 6 月。

[72] J. Schulman,F. Wolski,P. Dhariwal,A. Radford 和 O. Klimov, “近端策略优化算法”,2017 年, arXiv:1707.06347。

[73] Y. Sun,GG Yen 和 Z. Yi, “用于多目标优化问题的基于 IGD 指标的进化算法”, IEEE Trans.进化。计算机,卷. 23,没有. 2,第 173-187 页,2019 年 4 月。

[74] Y. Qian,S. Jia,J. Zhou 和 A. Robles-Kelly, “高光谱解混L1/2稀疏约束非负矩阵分解”, IEEE Trans. 地球科学.遥感,卷. 49,没有. 11,第 4282–4297 页,2011 年 11 月。

[75] F. Zhu,Y. Wang,B. Fan,S. Xiang,G. Meng 和 C. Pan, “通过数据引导的稀疏性进行光谱分解”, IEEE Trans.图像处理,卷. 23,没有. 12,第 5412–5427 页,2014 年 12 月。

[76] JM Bioucas-Dias 和 JMP Nascimento, “高光谱子空间识别”, IEEE Trans.地球科学.遥感,卷. 46,没有. 8,第 2435–2445 页,2008 年 8 月。

[77] S. Ruder, “梯度下降优化算法概述”, 2016 年 6 月, arXiv:1609.04747。

[78] P. Molchanov,S. Tyree,T. Karras,T. Aila 和 J. Kautz, “修剪卷积神经网络以实现资源高效推理”,2016 年, arXiv:1611.06440。

[79] L. Drumetz, M.-A. Vezanzones,S. Henrot,R. Phlypo,J. Chanussot 和 C. Jutten, “使用扩展线性混合模型解决光谱可变性的盲高光谱解混”, IEEE Trans.图像处理,卷. 25,没有. 8,第 3890–3905 页,2016 年 8 月。

[80] D. Hong,N. Yokoya,J. Chanussot 和 XX Zhu, “用于解决高光谱解混的光谱可变性的增强线性混合模型”, IEEE 跨.图像处理,卷. 28,没有. 4,页数 1923–1938,2019 年 4 月。

[81] J. Yao,D. Hong,L. Xu,D. Meng,J. Chanussot 和 Z. Xu, “稀疏性增强卷积分解:一种基于张量的新型盲高光谱解混范式”, IEEE Trans.地球科学.遥感,卷. 60,第 1-14 页,2022 年 4 月,doi: [10.1109/TGRS.2021.3069845](https://doi.org/10.1109/TGRS.2021.3069845)。

[82] K. Liu等人, “使用天宫一号高光谱遥感影像的场景分类数据集及其应用”, J. Remote Sens., vol. 24,没有. 9,第 1077–1087 页,2020 年 8 月。



朱涵 (IEEE 学生会员)于 2019 年在中国北京的华北理工大学获得电子工程学士学位。她目前正在攻读博士学位。中国科学院航天信息研究所数字地球科学重点实验室制图学与地理信息系统专业,北京。

她的研究兴趣包括高光谱图像处理、深度学习和人工智能。



洪丹峰 (高级会员,IEEE)获得理学硕士学位。 2015 年在中国青岛青岛大学信息工程学院获得计算机视觉学士学位 (最高荣誉) ,并获得 Dr.Ing. 2019 年德国慕尼黑工业大学 (TUM) 地球观测信号处理 (SIPEO)学位 (优异成绩) 。

他目前是中国科学院 (CAS) 航天信息研究所计算光学成像技术重点实验室的教授,中国北京。在加入 CAS 之前,他一直是一名研究科学家,并在位于德国 Oberpfaffenhofen 的德国航空航天中心 (DLR) 遥感技术研究所 (IMF) 领导光谱视觉工作组。他是法国格勒诺布尔格勒诺布尔阿尔卑斯大学格勒诺布尔理工学院 (Grenoble INP) CNRS GIPSA 实验室的兼职科学家。他的研究兴趣包括信号/图像处理、高光谱遥感、机器/深度学习、人工智能及其在地球视觉中的应用。

洪博士是 IEEE 地球科学与遥感汇刊 (TGRS)的专题副主编、遥感杂志的编辑委员会成员以及 ISPRS 摄影测量与遥感杂志的编辑顾问委员会成员。他是2021 年和 2022 年 IEEE 地球科学与遥感学报 (TGRS) 的最佳审稿人奖,2022 年 IEEE JOURNAL OF SELECTED TOPICS IN APPLIED EARTH OBSERVATIONS AND REMOTE SENSING的最佳审稿人奖,Jose Bioucas Dias 奖表彰 2021 年 WHISPERS 的杰出论文、2022 年遥感青年研究者奖和 2022 年 IEEE GRSS 早期职业奖。



Lianru Gao (高级会员,IEEE)于 2002 年获得中国北京清华大学土木工程学士学位,并获得博士学位。 2007 年毕业于中国科学院遥感应用研究所制图学与地理信息系统专业,获博士学位。

他于 2014 年在西班牙卡塞雷斯的埃斯特雷马杜拉大学和美国密西西比州斯塔克维尔的密西西比州立大学 (MSU) 担任访问学者。他目前是计算光学成像重点实验室的教授中国科学院航天信息研究所技术部。近十年主持国家部级科研项目10项,包括 2016-2019年、2018-2020年、2022-2025年国家自然科学基金项目和重点研究项目2013年至 2015年任中国科学院院士。发表同行评议论文180余篇,其中SCI收录期刊论文100余篇。他是三本学术书籍的合著者,包括高光谱图像信息提取。获得中国国家发明专利29项。他的研究重点是高光谱图像处理和信息提取。

高博士于2016年获得中国科学院杰出科技成果奖,2017年获得国家优秀青年科学基金资助, 2018年获得国家科技进步二等奖、 2015 年IEEE JOURNAL OF SELECTED TOPICS IN APPLIED EARTH OBSERVATIONS AND REMOTE SENSING最佳审稿人, 2017 年IEEE TRANSACTIONS GEOSCIENCE AND REMOTE SENSING最佳审稿人。



Bing Zhang (Fellow, IEEE) 于 1991 年在中国北京的北京大学获得地理学学士学位,并于 1991 年获得硕士和博士学位。分别于 1994年和2003年在北京中国科学院遥感应用研究所获得遥感学博士学位。

他目前是中国科学院航天信息研究所的正教授和副所长,在超过 25 年的时间里,他一直领导着高光谱遥感领域的许多重大科学项目。他开发了五个图像处理和应用程序系统。创作成果曾获中国政府十项重要奖励和国务院政府特殊津贴。

他撰写了 300 多篇出版物,其中包括 170 多篇期刊文章。他编辑了六本关于高光谱图像处理 and 后续应用的书籍/贡献的书籍章节。他的研究兴趣包括开发用于分析许多不同领域的高光谱遥感数据的数学和物理模型以及图像处理软件。

张博士自2011年起担任IEEE高光谱图像与信号处理研讨会技术委员会委员,自2012年起担任国际数字地球学会中国国家委员会高光谱遥感委员会主席,并担任国际数字地球学会常务理事。 2016年加入中国空间研究学会 (CSSR) ,2015年至2019年担任国际地球科学与遥感研讨会 (IGARSS)学生论文竞赛委员会委员。2013年获得国家杰出青年科学基金资助。并获得 2016年中国科学院杰出科技成果奖,这是中科院学者最高级别的奖项。他目前担任 IEEE JOURNAL OF SELECTED TOPICS IN APPLIED EARTH OBSERVATIONS AND REMOTE SENSING 的副主编。



Min Huang于 1999 年在中国合肥的中国科学技术大学获得学士学位,并于 1999 年获得博士学位。 2009年毕业于中国科学院西安光学精密机械研究所,获光学工程学士学位。

现任中国科学院航天信息研究所计算光学成像技术重点实验室教授。近10年,主持国家部级科研项目10项,其中包括中科院支撑技术重点研究计划项目、国家高技术研究发展计划项目。发表同行评议文章30余篇,获得中国国家发明专利20余项。他的研究重点是成像光谱学和计算光学成像。

黄博士于2010年获得国家科技进步二等奖。



Jocelyn Chanussot (研究员,IEEE)获得理学硕士学位。 1995 年获得法国格勒诺布尔理工学院 (Grenoble INP) 电气工程学士学位,并获得博士学位。 1998 年在法国安纳西萨瓦大学获得博士学位。

自 1999 年以来,他一直在格勒诺布尔 INP 工作,目前是信号和图像处理教授。他的研究兴趣包括图像分析、高光谱遥感、数据融合、机器学习和人工智能。他曾是美国加利福尼亚州斯坦福大学的访问学者;瑞典斯德哥尔摩 KTH 皇家理工学院;和新加坡国立大学 (NUS),新加坡。自 2013 年以来,他一直担任冰岛雷克雅未克冰岛大学的兼职教授。 2015年至2017年,他是美国加利福尼亚大学洛杉矶分校 (UCLA)的客座教授。他是 AXA 遥感主席,也是北京中国科学院航天信息研究所的兼职教授。

Chanussot 博士于 2012 年至 2017 年是法兰西大学学院的成员,也是高被引研究员 (Clarivate Analytics/Thomson Reuters)。 2007年至2010年任IEEE地球科学与遥感法国分会创始主席,获得2010年IEEE GRS-S分会优秀奖。曾多次获得优秀论文奖。他曾担任 IEEE 地球科学与遥感学会副主席,负责 2017 年至 2019 年的会议和专题讨论会。

他是第一届 IEEE GRSS 高光谱图像和信号处理、遥感进化 (WHISPERS) 研讨会的总主席。

他分别于 2009 年至 2011 年和 2005 年至 2008 年担任 GRS 数据融合技术委员会主席和联合主席。 2006 年至 2008 年,他是 IEEE 信号处理学会信号处理机器学习技术委员会的成员, 2009 年担任 IEEE 信号处理机器学习国际研讨会的项目主席。他是 IEEE TRANSACTIONS 的副主编关于地球科学和遥感、 IEEE图像处理会刊和IEEE会刊。 2011年至2015年担任IEEE JOURNAL OF SELECTED TOPICS IN APPLIED EARTH OBSERVATIONS AND REMOTE SENSING的主编。2014年担任IEEE Signal Processing Magazine的客座编辑。